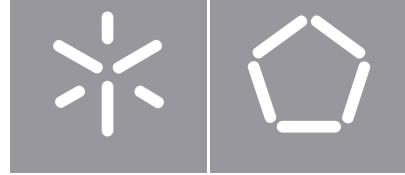




Universidade do Minho
Escola de Engenharia

Gonçalo Braz Afonso

OCR para documentos estruturados antigos
Old structured documents OCR



Universidade do Minho
Escola de Engenharia

Gonçalo Braz Afonso

OCR para documentos estruturados antigos
Old structured documents OCR

Dissertação de Mestrado
Mestrado em Engenharia Informática

Trabalho efetuado sob a orientação de
José João Antunes Guimarães Dias Almeida

Direitos de Autor e Condições de Utilização do Trabalho por Terceiros

Este é um trabalho académico que pode ser utilizado por terceiros desde que respeitadas as regras e boas práticas internacionalmente aceites, no que concerne aos direitos de autor e direitos conexos.

Assim, o presente trabalho pode ser utilizado nos termos previstos na licença abaixo indicada.

Caso o utilizador necessite de permissão para poder fazer um uso do trabalho em condições não previstas no licenciamento indicado, deverá contactar o autor, através do RepositórioUM da Universidade do Minho.

Licença concedida aos utilizadores deste trabalho:

[Caso o autor pretenda usar uma das licenças Creative Commons, deve escolher e deixar apenas um dos seguintes ícones e respetivo lettering e URL, eliminando o texto em itálico que se lhe segue. Contudo, é possível optar por outro tipo de licença, devendo, nesse caso, ser incluída a informação necessária adaptando devidamente esta minuta]



CC BY

<https://creativecommons.org/licenses/by/4.0/> [Esta licença permite que outros distribuam, remixem, adaptem e criem a partir do seu trabalho, mesmo para fins comerciais, desde que lhe atribuam o devido crédito pela criação original. É a licença mais flexível de todas as licenças disponíveis. É recomendada para maximizar a disseminação e uso dos materiais licenciados.]



CC BY-SA

<https://creativecommons.org/licenses/by-sa/4.0/> [Esta licença permite que outros remisturem, adaptem e criem a partir do seu trabalho, mesmo para fins comerciais, desde que lhe atribuam o devido crédito e que licenciem as novas criações ao abrigo de termos idênticos. Esta licença costuma ser comparada com as licenças de software livre e de código aberto «copyleft». Todos os trabalhos novos baseados no seu terão a mesma licença, portanto quaisquer trabalhos derivados também permitirão o uso comercial. Esta é a licença usada pela Wikipédia e é recomendada para materiais que seriam beneficiados com a incorporação de conteúdos da Wikipédia e de outros projetos com licenciamento semelhante.]



CC BY-ND

<https://creativecommons.org/licenses/by-nd/4.0/> [Esta licença permite que outras pessoas usem o seu trabalho para qualquer fim, incluindo para fins comerciais. Contudo, o trabalho, na forma adaptada, não poderá ser partilhado com outras pessoas e têm que lhe ser atribuídos os devidos créditos.]



CC BY-NC

<https://creativecommons.org/licenses/by-nc/4.0/> [Esta licença permite que outros remisturem, adaptem e criem a partir do seu trabalho para fins não comerciais, e embora os novos trabalhos tenham de lhe atribuir o devido crédito e não possam ser usados para fins comerciais, eles não têm de licenciar esses trabalhos derivados ao abrigo dos mesmos termos.]



CC BY-NC-SA

<https://creativecommons.org/licenses/by-nc-sa/4.0/> [Esta licença permite que outros remisturem, adaptem e criem a partir do seu trabalho para fins não comerciais, desde que lhe atribuam a si o devido crédito e que licenciem as novas criações ao abrigo de termos idênticos.]



CC BY-NC-ND

<https://creativecommons.org/licenses/by-nc-nd/4.0/> [Esta é a mais restritiva das nossas seis licenças principais, só permitindo que outros façam download dos seus trabalhos e os compartilhem.]

Ihem desde que lhe sejam atribuídos a si os devidos créditos, mas sem que possam alterá-los de nenhuma forma ou utilizá-los para fins comerciais.]

Agradecimentos

Escreva aqui os seus agradecimentos. Não se esqueça de mencionar, caso seja esse o caso, os projetos e bolsas dos quais se beneficiou enquanto fazia a sua investigação. Pergunte ao seu orientador sobre o formato específico a ser usado. (As agências de financiamento são bastante rigorosas quanto a isso.)

Declaração de Integridade

Declaro ter atuado com integridade na elaboração do presente trabalho académico e confirmo que não recorri à prática de plágio nem a qualquer forma de utilização indevida ou falsificação de informações ou resultados em nenhuma das etapas conducente à sua elaboração.

Mais declaro que conheço e que respeitei o Código de Conduta Ética da Universidade do Minho.

Universidade do Minho, Braga, outubro 2024

Gonçalo Braz Afonso

Resumo

A digitalização de documentos permitiu uma nova forma de salvaguardar informação para a posteridade, evitando a sua perda pelo deterioramento físico destes. De forma a posteriormente transcrever estes documentos, permitindo uma consulta, processamento e manipulação mais simples, o uso de software de **OCR** é essencial. Esta tecnologia é, no entanto, dependente em diferentes níveis das características do seu alvo, nomeadamente: qualidade da imagem, complexidade da estrutura do documento, linguagem do texto.

Documentos mais antigos, em especial jornais por apresentarem estruturas mais complexas, apresentam por este motivo resultados que diferem bastante do seu conteúdo original; tanto a nível do texto reconhecido, como da sua organização para os diferentes outputs disponíveis (ex.: txt simples). A tarefa de extrair informação destes documentos, como por exemplo o isolamento e extração de artigos, torna-se assim complexa e propensa a erros.

Este trabalho propõe então a criação de uma ferramenta ou um conjunto de ferramentas que permitem auxiliar o processo de extração de conteúdo de documentos, primeiramente mas não exclusivamente, mais antigos e estruturados, com especial foco em jornais. A pipeline do projeto pretende então ser capaz de detetar e lidar com os diferentes pontos de risco nestes documentos: qualidade da imagem, erros nos resultados de **OCR**, segmentação e organização do documento, criação do output organizado.

Diferentes alternativas para **OCR** assim como métodos de tratamento destes problemas serão estudados, comparados, e implementados, de forma a encontrar a melhor solução para a resolução deste problema. O produto final implementado será composto por uma ferramenta utilizável num formato **GUI** ou comando de consola.

Para documentos antigos a linguagem, como mencionado, pode afetar os resultados de **OCR**. Deste modo, como objetivo secundário, propõe-se a criação de uma ferramenta que facilite a criação de um dicionário para diferentes iterações de uma linguagem para: fornecer ao motor **OCR** um léxico mais apropriado; modernizar o conteúdo extraído.

Palavras-chave OCR, Digitalização, Documentos estruturados, Documentos antigos, Segmentação de documentos, Tratamento de imagem, Modernização de texto

Abstract

The digitization of documents has opened a new way of preserving information for posterity, avoiding its loss through their physical decay. To allow the transcription of these documents, enabling an easier search, indexation and manipulation of them, the use of **OCR** software is essential. This technology is, however, dependent in many ways of the characteristics of its target, namely: the quality of the image, the complexity of the document's structure, the text's language.

Older documents, especially newspapers for having complex structures, result in poor transcriptions that differ from their original content, both in the recognized text, and in the organization of the available final outputs (ex.: simple txt). Extracting information from these documents, for example, the isolation and extraction of articles, becomes thus a complex and error prone task.

Therefore, this work aims to create a tool, or a toolkit, that can assist in the process of content extraction from documents, primarily though not exclusively, that are older and structured, specializing in newspapers. The proposed pipeline should then be able to detect and fix potential problems in these documents: image quality, **OCR** results errors, segmentation and document organization, restructured output generation.

Different **OCR** alternatives, as well as different methods of dealing with these problems, will be studied, compared, and implemented, to find the best solution for the task at hand. The final product will be composed of a tool usable in both a **GUI** and bash command format.

For old documents, its language, as mentioned, may affect the **OCR**'s performance. Therefore, as a secondary objective, it's proposed the development of a tool that allows for the creation of dictionaries for different versions of a given language that can be used to: supply the **OCR** engine with a more appropriate lexicon; modernize the extracted content.

Keywords **OCR**, Digitalization, Structured documents, Old documents, Document segmentation, Image treatment, Text modernization

Conteúdo

1	Introdução	1
1.1	Enquadramento e motivação	1
1.2	Objetivos	2
1.3	Estrutura da dissertação	3
2	O problema e os seus desafios	5
2.1	Desafios	5
2.2	Plano da Solução	6
3	Estado da arte	8
3.1	Reconhecimento ótico de caracteres	8
3.1.1	Introdução	8
3.1.2	Breve história e evolução	9
3.1.3	Processo OCR	10
3.1.4	Desafios	11
3.1.5	Tecnologia	12
3.2	Pré Processamento para OCR	13
	Métricas de avaliação	16
3.3	Pós Processamento para OCR	17
	Junção de Outputs de OCR	18
	Vias lexicais	19
	Modelos de erro e Máquinas de estado finitas com pesos	19
	Modelos de linguagem baseados em tópicos	19
	Modelos de linguagem	20
	Machine Learning baseado em características	20
	Seq2Seq - Sequência para Sequência	20

Métricas de avaliação	21
3.4 Segmentação de documentos	21
Algoritmos dedicados a um layout específico	22
Algoritmos que usam parâmetros para descrever um layout	22
Algoritmos para segmentação de layout potencialmente não restringidos	23
3.5 Trabalho relacionado	23
3.5.1 Extração de conteúdo de jornais	23
Heurísticas	24
Inteligência artificial	25
3.5.2 Ordem de leitura	25
3.6 Outros	27
3.7 Conclusões	27
4 OSDOCR Filosofia	28
4.1 O problema	28
4.2 Modelos	32
4.2.1 Imagem	32
4.2.2 OCR Tree - estrutura de dados para resultados OCR	32
4.3 Arquitetura da solução	34
4.3.1 OSDOCR Toolkit	35
4.3.2 OSDOCR Pipeline	35
4.3.3 OSDOCR Editor	37
5 OSDOCR Estruturas de Dados - Implementação	38
5.1 OCR Tree	38
5.2 Box	48
6 OSDOCR Toolkit - Implementação	53
6.1 Sumário	53
6.2 Processamento de resultados OCR	54
6.3 Processamento de imagem	69
6.4 Processamento de texto	79
7 OSDOCR Pipeline - Implementação	80

7.1	Sumário	80
7.2	Pré-processamento de imagem	85
7.3	OCR	87
7.4	Pós-processamento de OCR	89
7.5	Geração de output	91
7.6	Validação de resultados	92
8	OSDOCR Editor - Implementação	94
8.1	Sumário	94
8.2	Funcionalidades	95
8.2.1	Inputs	95
8.2.2	Manipulação manual de OCR Tree	95
8.2.3	Aplicação local de OCR	96
8.2.4	Ferramentas disponíveis	96
8.2.5	Outputs	99
8.2.6	Operações adicionais	99
9	Resultados	101
9.1	Casos de estudo	101
9.2	OSDOCR Toolkit	101
9.3	OSDOCR Pipeline	101
9.4	OSDOCR Editor	101
10	Conclusões e trabalho futuro	102
10.1	Conclusões	102
10.2	Perspetiva de trabalho futuro	102
I	Apêndices	108
A	Trabalho de apoio	109
B	Detalhes dos resultados	110
C	Listings	111

Lista de Figuras

1	Pipeline da solução	6
2	Aplicação de OCR com passos para melhoria de resultados	29
3	Exemplo de pipeline de aplicação de OCR	29
4	Exemplo de pipeline de aplicação de OCR com blocos opcionais	30
5	Representação visual dos resultados de OCR armazenados em formato HOCR	33
6	Arquitetura geral da solução	34
7	Arquitetura OSDOCR Toolkit	35
8	Arquitetura OSDOCR Pipeline - high level	36
9	Arquitetura OSDOCR Pipeline - reduzida	36
10	Arquitetura MVC	37
11	Árvore de resultados OCR num documento	40
12	Variação dos resultados de OCR em diferentes níveis de rotação de texto.	70
13	Exemplo de aplicação do algoritmo. 1^a imagem representa a imagem do documento original. 2^a imagem representa a identificação dos pixels à esquerda no documento. 3^a apresenta os 3 maiores sets de cada tipo: set de pixels com mesmo x (azul); set de pixels counter-clockwise (verde); set de pixels clockwise (vermelho). 4^a mostra o ângulo de rotação calculado a partir do maior set. 5^a tem a imagem corrigida.	71
14	Exemplo de documento com inclinação de texto e sombra de bainha.	72
15	Exemplo de resultado de OCR com diferentes binarizações em local com pouco ruído.	74
16	Exemplo de resultado de OCR com diferentes binarizações em local com muito ruído.	74
17	Pipeline - secção pré-processamento	85
18	Pipeline - secção OCR	87
19	Pipeline - secção pós-processamento	89

20	Pipeline - secção output	91
----	------------------------------------	----

Lista de Tabelas

Capítulo 1

Introdução

Neste capítulo, será realizada uma introdução ao problema que o projeto tenciona abordar, composta por uma contextualização do seu estado atual e os desafios que sobre este são impostos. Além disso, os objetivos do trabalho serão listados e será descrita a estrutura do documento.

1.1 Enquadramento e motivação

A digitalização tem um papel fundamental na conservação, disponibilização e proliferação de documentos físicos, não só contemporâneos, mas também de eras anteriores à revolução da informação. Esta tecnologia, acoplada a ferramentas de **OCR**, veio trazer uma facilidade de navegação, consulta e manipulação destes documentos que anteriormente não era possível.

A eficácia de **OCR** é no entanto dependente de vários fatores nas imagens ou ficheiros alvo: a qualidade das imagens, como a resolução, estado do documento, coloração, qualidade/tipo de escrita; a estrutura dos documentos - quanto mais complexo, mais difícil é obter a informação de forma automática mantendo a congruência original -; linguagem do texto, sendo que por vezes diferentes tecnologias, como por exemplo **Tesseract**, procuram verificar a sua confiança na deteção com o vocabulário conhecido, o qual pode não coincidir com a época de produção do documento; entre outras.

Estas dependências são especialmente notórias quando se envolvem documentos mais antigos, os quais podem, além de apresentar envelhecimento causado pelo tempo e danos pelas condições de armazenamento, devido às limitações tecnológicas assim como por vezes à falta de convenções de formatação dos documentos, não dispor de uma consistência no formato e texto (estrutura, alinhamento, dimensões dos caracteres, fonte de texto consistente, etc.) usual nos documentos atuais. Estes fatores resultam então num reconhecimento de texto não tão satisfatórios.

Estes documentos antigos são mais comumente, mas não exclusivamente, reconhecidos como anteriores à era digital, sendo que o foco de trabalho será maioritariamente dirigido a documentos desta

época, como jornais, revistas e outros, do século passado ou anteriores. Em especial documentos com estruturas complexas, como é o caso de jornais, onde é possível a segmentação em diferentes partes com conteúdo e propósito distinto e, ao mesmo tempo, uma ordem de leitura complexa i.e., não segue apenas regras simples de posição do conteúdo (texto da esquerda antes do texto da direita e cima antes de baixo), exigindo também noção das características e relação do conteúdo.

Mesmo para ficheiros do tipo **hOCR** ou **PDF**, que já passaram por um processo de reconhecimento de texto, a complexidade da estrutura dos documentos originais ou problemas nos elementos que contém o texto (como por exemplo elementos sobrepostos ou que se intersetam) dificultam a extração e interpretação do seu conteúdo, podendo ser facilmente perdida a lógica original.

Por estas razões, seria útil uma ferramenta que permita uma deteção e tratamento destes documentos de forma automática e de uso simples, permitindo um certo nível de configuração para adaptação entre tipos de documentos com características bem definidas e distintas.

O presente documento pretende então servir como um estudo dos desafios apresentados por estes tipos de documentos perante **OCR**, assim como a procura de soluções para a melhoria dos resultados na deteção e extração de texto e assim criar uma ferramenta que torne o processo de extração de informação destes tipos de documentos mais simples e fiável.

Como trabalho complementar, é proposta a implementação de um método de modernização do conteúdo extraído, envolvendo a criação de uma ferramenta capaz de criar dicionários entre diferentes iterações de uma mesma linguagem.

1.2 Objetivos

O principal objetivo deste trabalho é a realização de um estudo sobre os problemas apresentados à extração de conteúdo de documentos de estrutura complexa - mantendo a sua lógica original -, assim como a implementação de uma solução para resolver ou mitigar estes desafios, aumentando a confiança na informação extraída. Em termos dos casos alvo do trabalho, será prioridade o estudo de jornais com texto máquina. Tal deve-se ao facto de jornais serem um particular tipo de documento que apresenta mais dificuldades e se encontra em maior procura de soluções e, texto máquina por ser mais comum para este tipo de documento. Esta segunda restrição é menos relevante pois não é uma dificuldade do trabalho e pode ser resolvida perante a escolha da tecnologia de reconhecimento utilizada.

Especificando, os objetivos do trabalho são:

- Estudar os diferentes softwares de **OCR** disponíveis e as diferenças entre estes.

- Estudar as dificuldades que documentos podem apresentar no processo de reconhecimento de texto.
- Estudar o trabalho desenvolvido sobre a área de tratamento de imagem, identificação de tipo de documento, segmentação de documentos, algoritmos de cálculo da ordem de leitura, melhoria de resultados de **OCR** e métricas de validação de resultado **OCR**.
- Estudar trabalhos com âmbito similar ou relacionado ao presente.
- Implementação de um conjunto de ferramentas dirigidas à solução dos problemas propostos.
- Implementação de uma ferramenta em formato **GUI** e comando de consola que aplique uma pipeline cujo input seria um ficheiro - imagem, pdf, hOCR -, identifique e trate de problemas deste se necessário para melhorar os resultados de **OCR** e, por fim, devolva um output que mantenha a lógica e conteúdo do documento original.
- Secundário : ferramenta para criação de dicionário de diferentes versões de uma linguagem para: modernização de texto; léxico de motor **OCR**. Ferramenta tem como input duas versões de um documento na mesma linguagem mas iterações diferentes e dá como output um dicionário entre as versões.
 - Estudo sobre criação de léxicos e alinhamento de documentos.

Englobando todo o trabalho prático desenvolvido, a solução implementada será nomeada "Old Structured Documents OCR"(**OSDOCR**).

1.3 Estrutura da dissertação

Esta dissertação segue a seguinte estrutura:

- Capítulo 1: Breve contextualização sobre o tema proposto, as dificuldades impostas por documentos estruturados e com digitalizações ou condições físicas degradadas, nos resultados **OCR**, e a utilidade de uma ferramenta para o tratamento destas. Além disso foram listados os objetivos do trabalho.
- Capítulo 3: Estudo sobre o estado da arte nos tópicos relacionados ao tema da dissertação, as suas dificuldades e soluções destas; estudo de trabalho anteriormente realizado com âmbito similar ao atual ou técnicas relevantes para a construção da solução do problema.

- Capítulo 2: Listagem dos diferentes problemas que a solução irá abranger e os desafios que estes apresentam. Apresentação do desenho da solução.
- Capítulo ??: Descrição da solução e ferramentas implementadas.
- Capítulo ??: Apresentação e estudo dos resultados do trabalho realizado.
- Capítulo 10: Reflexão sobre o trabalho realizado, os resultados e a experiência obtida, assim como uma breve exploração de caminhos para trabalho futuro do projeto.
- Capítulo ??: No último capítulo é explicado o plano de desenvolvimento da dissertação.

Capítulo 2

O problema e os seus desafios

Neste capítulo, é feita uma síntese dos desafios do problema e uma discussão sobre a solução desenhada até ao momento para concretizar os objetivos definidos.

2.1 Desafios

No capítulo 3, realizou-se um estudo abrangente sobre o estado da arte no que toca a projetos que utilizem **OCR** e trabalhos relacionados com os objetivos listados para este projeto (1.2). Através deste estudo, foi possível extrair um leque de problemas detetados na utilização de reconhecimento de texto em documentos, de forma generalizada ou para tipos específicos como é o caso deste trabalho. Em suma, os principais desafios são:

- **Problemas de imagem** : tanto na imagem de input, como no documento original. Ex.: ruído, baixa resolução, má iluminação.
- **Problemas de reconhecimento** : estes são muitas vezes derivados do conjunto anterior, mas outras questões como léxico no documento desconhecido pelo motor OCR ou estruturas complexas podem provocar erros no reconhecimento.
- **Problemas nos resultados** : consideremos estes os problemas sobre as entidades reconhecidas pelo software, tanto o texto que em muitos casos apresenta erros como os próprios contentores em que estes são incluídos.
- **Problemas na extração de conteúdo** : no processo de criação de output, por vezes questões como a ordem de leitura dos blocos identificados, ou reposição de elementos não texto têm de ser abordados.

- **Validação da implementação** : de forma a verificar a eficácia da solução criada, geralmente datasets de teste e casos de estudo relevantes têm de ser criados.

2.2 Plano da Solução

Durante o estudo do estado da arte, tornou-se evidente que a maioria dos trabalhos com vista em extrair ou corrigir a extração de documentos utilizando reconhecimento de texto, de forma a manter o conteúdo e lógica original, seguem uma metodologia semelhante: uma primeira fase de pré processamento da imagem de input; possível segmentação da imagem entre texto e não texto; reconhecimento de texto; pós processamento do texto; possível pós processamento para segmentação de conteúdo específico de um tipo de ficheiro, como artigos, ou para reorganização dos resultados (ordem de leitura); criação de output.

Partindo desta base, a figura 1 representa o fluxo da solução planeada atualmente.

A pipeline começa com a introdução de um input, podendo este ser sujeito de reconhecimento de texto, no caso de ser uma imagem, ou já possuir os resultados de reconhecimento, como hOCR. No caso de uma imagem, antes de ser aplicado o software de OCR, será realizado pré processamento da imagem para aumentar a chance de bons resultados de OCR.

Os resultados de OCR são então convertidos para uma estrutura de dados genérica, de modo a englobar os diferentes tipos de resultados possíveis de diferentes tipos de ficheiros ou motores de OCR. Em diante, esta estrutura será usada nos módulos que utilizam os resultados de OCR.

Depois, passa-se por um processo de pós processamento básico dos resultados de OCR. Tal tem o intuito de corrigir erros menos severos no que toca às *bounding boxes* dos resultados e lixo reconhecido pelo motor.

Uma análise dos resultados limpos é então realizada, extraíndo in-




Figura 1: Pipeline da solução

formação sobre o texto reconhecido, estimas do possível layout, erros de reconhecimento, etc.. Com os resultados da análise feita, abre-se a possibilidade de realizar um tratamento de imagem diferente dedicado à resolução de problemas detectados, por exemplo: detetado um **DPI** de imagem muito baixo, este é um indicador de que a resolução da imagem poderia ser aumentada para melhorar o reconhecimento, procedimento comum no estudo feito.

Utilizando os resultados da análise, são de pois aplicados algoritmos para extração do conteúdo do documento. Aqui o principal objetivo será o cálculo da ordem de leitura e agrupamento dos elementos em conjuntos como artigos. Além disso, o objetivo secundário envolvente da modernização de texto poderá nesta etapa ser aplicado.

Finalmente, o output final é gerado. Diferentes formas de output serão disponibilizadas dependendo da estrutura pretendida, por exemplo: markdown ou texto simples no caso de apenas se querer os elementos do texto isolado; html para reconstruir a estrutura do documento original.

Capítulo 3

Estado da arte

Neste capítulo, será feita uma exposição do estado da arte das tecnologias relacionadas com o tema ou relevantes para o projeto, assim como trabalhos relacionados, quer no mesmo tema ou envolvente - algoritmos relevantes para o desenvolvimento -, procurando plantar uma base para o trabalho realizado e futuro, entendendo o que já foi explorado e o que está para vir em alguns casos. O capítulo começa com uma apresentação sobre **OCR** que será a tecnologia pilar do trabalho (3.1), seguido por uma exploração de processos de melhoria dos resultados de reconhecimento usando pré (3.2) e pós processamento (3.3). Procede-se o tema de segmentação de documentos (3.4), terminando com o estudo de trabalho relacionado (3.5).

3.1 Reconhecimento ótico de caracteres

3.1.1 Introdução

O reconhecimento ótico de caracteres é a tecnologia base do projeto proposto, estando presente em qualquer instância ou caso de estudo que será explorado, inclusive em exceções que não necessitam a aplicação de reconhecimento de caracteres, como ficheiros do género **hOCR**, pois estes já são um produto de **OCR**.

Na sua essência e como o nome indica, software de reconhecimento ótico de caracteres permitem a deteção e transcrição de texto a partir de imagens, de forma automática e autónoma. Utilizando esta habilidade, abriu-se a possibilidade de tornar os documentos digitalizados ao longo do tempo numa fonte mais útil de informação: navegada, consultada e editada mais facilmente, visto estes serem na maioria dos casos, digitalizados na forma de imagens. A adição do conteúdo destes documentos através da sua transcrição, mesmo que apenas parcialmente correta, permite a adição de, por exemplo, meta-dados ou palavras chaves que auxiliam a sua indexação.

3.1.2 Breve história e evolução

Srihari et al. [2003] e Berchmans and Kumar [2014] apresentam a história do reconhecimento ótico de caracteres desde a conceção do seu ideal no século XIX, como uma tecnologia para auxílio de pessoas com impedimentos na leitura, até aos pontos alcançados na última década onde até escrita humana se tornou num desafio, até certo ponto, conquistável. As primeiras instâncias de reconhecimento óptico realizado por máquinas deu-se no final do séc. XIX, mais especificamente em 1870 por Charles R. Carey com a criação de um scanner de retina, mas é necessário ir até meio do século seguinte e pela consequente evolução que decorreu nesta área, para a subárea de reconhecimento de caracteres começar a ver a sua comercialização com a invenção de David Shepard: GISMO, um sistema simples capaz de reconhecer texto .

A génese desta tecnologia começou num formato bastante limitado, sendo capaz apenas de reconhecer um conjunto muito limitado de caracteres de uma fonte específica a um ritmo de 1 carácter por minuto, isto em condições de input bem controladas (papel sem ruído, apenas com o texto a ser reconhecido). Esta é considerada por Berchmans and Kumar [2014] como a primeira geração de **OCR**.

A segunda geração começa a dar os primeiros passos no processamento de escrita humana, como é exemplo o *IBM 1287* na década de 60.

A terceira geração, nas décadas de 70 e 80, introduziu um maior foco no processamento da escrita humana e na capacidade de lidar com problemas na imagem original.

A quarta geração tornou-se capaz de tratar documentos complexos com misturas entre texto e imagens, assim como qualidades de inputs menos favoráveis, documentos com cor e mais precisão com texto manuscrito.


Atualmente com a evolução das técnicas de pré processamento, assim como os algoritmos de reconhecimento e a ascensão da inteligência artificial [Mittal and Garg, 2020], a precisão e flexibilidade dos softwares de **OCR** são capazes de, até em imagens de paisagens, segmentar e reconhecer texto localmente de forma automática e com pouco pré processamento. Além disso, embora o foco anteriormente era em software **OCR** pago e dedicado a um tipo específico de documentos, a implementação de softwares mais geral e de uso aberto tem-se tornado mais vulgar. Em algumas instâncias complexas - documento complexo e linguagem com caracteres fora do latim -, já existe tecnologia capaz de obter taxas de acerto acima dos 95% mesmo para texto escrito à mão [Mittal and Garg, 2020].

3.1.3 Processo OCR

Um software **OCR** pode ter reconhecimento online ou offline [Srihari et al., 2003][Berchmans and Kumar, 2014]. O primeiro é reconhecimento em tempo real, em que usualmente o input é obtido num dispositivo dedicado como um tablet digitalizador, no formato de um conjunto de coordenadas, podendo portanto ser mais preciso a custo de menor flexibilidade na entrada. O mais comum, método offline, recebe como um input por norma uma imagem com o documento finalizado. O bitmap desta imagem será utilizado como alvo do reconhecimento de caracteres. O uso deste último método, com tipo de entrada menos controlado, exige uma fase de pré processamento mais minuciosa do que o reconhecimento online.

Neste trabalho, o foco será dado ao reconhecimento offline por ser o mais comum e aquele que permite o tratamento de documentos pré digitalizados. Este pode ser geralmente dividido em 6 partes:

- **Aquisição de input** : imagem a ser reconhecida, incluindo algoritmos de compressão do próprio formato guardado.
- **Pré processamento** : técnicas de manipulação do input para melhorar resultado de **OCR**
- **Segmentação** : segmentação do input, a vários níveis, de modo a isolar o melhor possível os conteúdos relevantes, i.e. o texto.
- **Extração de características** : processo de reconhecimento de características dos caracteres isolados.
- **Classificação** : utilizando as características calculadas é feita a decisão sobre a sua identidade.
- **Pós processamento** : técnicas para melhoria do resultado como, por exemplo, a correção de erros ortográficos. Por vezes pode alterar o documento original se a **ground truth** já contiver estes erros.



O **Pré Processamento** é um passo essencial para o aumento do acerto do reconhecimento de texto, sendo que ele pretende remover imperfeições do input como: baixo contraste das linhas, texto mal delimitado, ruído de imagem, orientação do documento ou do texto (principalmente manuscrito). Em alguns casos mais complexos, com ajuda de inteligência artificial, também é possível a reposição de partes parciais de uma imagem que foram perdidas, ou remoção de elementos como **watermarks**.

A **Segmentação** é usada para isolar o conteúdo útil do resto da imagem podendo envolver vários passos como: segmentação da página para separar texto do resto do conteúdo; segmentação de caracteres, com o intuito de os separar em caracteres individuais, algo que é especialmente difícil com escrita à mão devido à tendência em criar ligações entre caracteres ou mesmo de os unir; tratamento e normalização dos caracteres isolados - normalização do tamanho, filtração morfológica.

A **Extração de Características** (Feature Extraction) trata-se do processo de deteção e cálculo das características dos caracteres, para a criação do classificador (dependendo da arquitetura) e anotação do que distingue o caráter alvo. Este processo é possivelmente o mais aberto para variações e que, juntamente com o classificador, mais influencia o resultado. Diferentes técnicas de extração de características e **Classificação** são utilizadas e foram estudadas durante as últimas décadas: desde *template matching* [Srihari et al., 2003] onde são usados algoritmos para cálculo de similaridade entre um template e o alvo, a segmentação de características, como presença de loops ou traços verticais longos [Srihari et al., 2003], ou distribuições de pixels [Mittal and Garg, 2020]. Para texto humano, este processo torna-se ainda mais complexo devido à necessidade de lidar com múltiplos caracteres invés de singulares. A classificação passava por um processo de comparação do valor das características calculado com diferentes templates porém, mais recentemente, o uso de estratégias no ramo de machine learning são mais comuns: redes neurais, support vector machines e k- nearest neighbor; são alguns dos modelos mais utilizados [Mittal and Garg, 2020] Berchmans and Kumar [2014]. Por vezes, o classificador utiliza conhecimento do léxico de uma linguagem para ajudar na sua classificação, sendo que documentos com linguagem desatualizada poderão sofrer nesse caso.

O **Pós Processamento** é responsável pelo tratamento do output, responsável por mitigar ou corrigir alguns erros do reconhecimento, desde correções ortográficas a posicionamento na página [Mittal and Garg, 2020].

Este trabalho irá ter como foco principal as secções de pré e pós processamento, e segmentação, na procura de aumentar a eficácia do reconhecimento e da organização dos resultados.

3.1.4 Desafios

Com a evolução da tecnologia, os problemas foram mudando de foco, tendo passado por um longo período em que a maior prioridade era a capacidade de reconhecimento de caracteres para além de um escopo limitado, tanto em termos de identidade como estilo, para a capacidade de tratar a imagem de forma a que o reconhecimento tenha uma maior taxa de acerto [Bieniecki et al., 2007]. Alguns dos maiores desafios atualmente para **OCR** são:

- **documento original** : danos no objeto; texto ilegível ou com um tipo de letra muito complexo; linguagem desatualizada; estrutura complexa; inclinação do texto; distorções da página.
- **imagem** : má iluminação; múltiplas páginas com diferentes orientações; baixa resolução; pouco contraste; ruído.
- **classificador ou extrator de features** não adequado para uma dada linguagem.
- **resultado** : validação quando não se tem a **ground truth** disponível

Dentro destes, o processamento de estruturas complexas será o foco principal e o expectável maior contributo deste trabalho.

3.1.5 Tecnologia

Presentemente, com a proliferação permitida pela internet e a globalização, a disponibilização de ferramentas de **OCR**, anteriormente primariamente privilégio de instituições ou empresas, como bancos [Srihari et al., 2003], tornou-se trivial, acessível através de itens do dia a dia como um computador ou telemóvel de forma gratuita, ex.: Google Lens.

Alguns destes softwares que serão utilizados neste trabalho são:

- **Tesseract**
- **Keras-OCR**
- **PaddleOCR**

Os resultados deste tipo software podem ser genericamente descritos como uma lista de caixas, delimitadoras de texto, com conteúdo, i.e. o texto nela contido e, por norma, um nível de confiança no reconhecimento desse texto.

No caso do **Tesseract** [Tesseract], dentro das várias formas que os resultados podem ser apresentados, a lista de caixas pode ser interpretada como uma árvore de blocos, em que cada nível corresponde a um tipo de estrutura no documento: página → bloco → parágrafo → linha → texto.

Usando **PaddleOCR** [PaddleOCR], os resultados são mais simples, divididos apenas pelas linhas de texto detetado.

Já o **Keras-OCR** [KerasOCR] lista um conjunto de caixas em que cada contém uma palavra reconhecida.

Uma outra característica que o **Tesseract** tem é a capacidade de reconhecer, com nível de acerto variável, outros elementos relevantes de um documento, como imagens ou delimitadores. Isto pode, por outro lado, causar erros na interpretação dos resultados por sobreposição ou multiplicação da quantidade de caixas. Além disso o **Tesseract** permite bastantes configurações como: léxico esperado; modo de segmentação; reconhecimento de espaços em branco; etc.

O output deste tipo de software pode ainda ser processado para tomar diversas formas: formatos que apenas retêm o conteúdo como texto simples ou markdown; formatos que mantêm informação sobre os blocos detetados, como hOCR.

A validação do output é na maioria dos casos medida a partir da comparação com a **ground truth**, o que limita a capacidade de testar e treinar (no caso de **ML** supervisionado) modelos visto que os datasets tem de ser criados de forma minuciosa e consumidora de tempo.

Além dos softwares de reconhecimento, é preciso ter atenção ao tipo dos ficheiros de entrada. Estes são usualmente imagens e, dependendo do tipo de **codec** destes, os algoritmos de compressão aplicados poderão diminuir a qualidade de imagem, como é o caso de formatos *lossy* como **JPEG**, potencialmente diminuindo o acerto do reconhecimento do texto. [Darwiche et al. \[2015\]](#), no seu estudo demonstra que mesmo entre diferentes tipos de *lossy* **codec** o seu impacto pode variar significativamente nos resultados de **OCR**, sendo que o formato **JPEG**, um dos mais populares, resultou nas menores taxas de sucesso.

3.2 Pré Processamento para OCR

Como foi listado na secção [3.1.4](#), existe uma diversa quantidade de defeitos que os documentos originais e as imagens digitalizadas destes podem ter e cuja presença pode afetar negativamente os resultados de software de **OCR**. O pré processamento pode ser considerado como uma fase de tratamento de imagem para remover estes problemas que deterioram o reconhecimento de texto. De forma a entender os diferentes métodos utilizados e a sua evolução para o presente, foram selecionados os estudos: [\[Bieniecki et al., 2007\]](#),[\[Likforman-Sulem et al., 2009\]](#),[\[Souibgui and Kessentini, 2022\]](#),[\[Lat and Jawahar, 2018\]](#),[\[Dey et al., 2022\]](#),[\[Wei et al., 2018\]](#),[\[Bui et al., 2017\]](#).

Entre o grande leque de diferentes algoritmos e tratamentos que podem ser aplicados nas imagens, em geral, estes podem ser segmentados nos mais comuns [\[Dey et al., 2022\]](#):

- **binarização/thresholding da imagem** : processo de normalização dos pixeis para um de dois valores, mediante um determinado limiar
- **remoção de ruído** : algoritmos para retirar degradações ou sujidades da imagem através de

processos como, por exemplo, suavização da imagem calculando para cada pixel o valor médio da sua vizinhança

- **correções de texto** : alguns casos deste são texto que apresenta um ângulo de rotação, texto com inclinação, distorções locais no texto, *watermarks*
- **super-resolução** : aumentar a resolução da imagem, consequentemente aumentando o seu **DPI**
- **foco da imagem** : acentuação das arestas, diminuir desfocagem
- **transformações morfológicas** : operações sobre a imagem de modo a provocar maior contraste do conteúdo, ou permitir melhor distinção das características, ex.: dilatação do texto para tornar mais fácil a distinção entre regiões com e sem texto.

Para **binarização**, o objetivo principal é distinguir o texto do resto da imagem, daí a alocação dos pixels para 1 de dois valores. Este processo é distinguido principalmente entre o uso de *thresholding* global ou local (ou adaptativo), sendo que o global implica um cálculo das características estatísticas locais dentro da imagem, e é mais adequado para o tratamento de imagens com cor, ou com variações de intensidade dispersas pela imagem [Dey et al., 2022]. Alguns dos algoritmos mais comuns são comparados por Souibgui and Kessentini [2022], onde é evidente a dependência destes nas condições do documento original e da imagem. Um exemplo apresentado demonstra como, numa imagem com uma mancha escura (com o texto ainda distinguível), o algoritmo de Otsu conseguiu gerar uma imagem com pouco ruído e bom contraste, mas a zona da mancha fica completamente preta, comparado ao algoritmo de Niblack que, embora com mais ruído, recuperou algum texto dentro da mancha.

A **remoção de ruído** é possivelmente a área com mais alternativas possíveis e das que mais afeta o resultado do reconhecimento por, a nível de pixels, o ruído interferir com a composição dos caracteres ou criar acumulações de informação extra que serão mal identificadas pelos softwares, como notado por Bieniecki et al. [2007]. O ruído nas imagens pode ser de vários tipos, o que dificulta a forma de o detetar e tratar. Alguns dos outros tratamentos, como a binarização, transformações morfológicas e alguns tipos de super-resolução, também tratam desta questão mesmo não sendo o seu foco principal. Da mesma forma, alguns dos filtros utilizados podem ter outros resultados como o aumento do contraste ou eliminação de distorções. Alguns dos tratamentos mais comuns do ruído são [Dey et al., 2022][Bui et al., 2017][Bieniecki et al., 2007]:

- filtro Gaussiano
- médias não locais

- suavização com filtro de mínimos locais
- suavização com filtro Wiener

Vários destes métodos resultam tanto na acentuação das arestas do texto, como na remoção de lixo ou ruído à sua volta, recuperando o **foco da imagem**.

A **correção de texto** necessita, ao contrário dos outros processos que podem, mesmo sem uma análise prévia do estado da imagem, melhorar o reconhecimento de texto; de uma análise prévia visto que, por exemplo, não se pode aplicar uma rotação na imagem sem saber o ângulo de orientação inicial desta. [Bieniecki et al. \[2007\]](#) faz uma apresentação convincente do efeito de uma rotação de ângulo 15° no reconhecimento do Tesseract, o que impediu o reconhecimento. O método proposto passa pelo computação de uma linha que afete a margem na extremidade esquerda do texto, de modo a calcular a sua inclinação relativa à margem da imagem e assim descobrir o ângulo de rotação do texto. No espectro mais limitado da sua proposta, devido à sua localidade nos documentos, [Bieniecki et al. \[2007\]](#) discute distorções nos documentos como curvaturas resultantes da bainha de um livro. Aqui, em traços gerais, a linha de curvatura do texto é detetada, com a qual é criado um quadrilátero da área afetada, onde será, de acordo com o nível de curvatura na projeção sobre a linha, realizada a correção. Em ambos os casos, os resultados demonstrados para casos de grande deformação, os algoritmos propostos conseguiram tornar a completa falha de reconhecimento para taxas de acerto dentro dos 99%.

A aplicação de **super-resolução** procura auxiliar o processo de reconhecimento ao melhorar a qualidade de imagens de baixa resolução, i.e. aumentar os seus **DPI** e tornar os caracteres mais reconhecíveis. Entre os vários algoritmos utilizados para este propósito, o uso de interpolação tendia a ser o mais comum, porém nem sempre os resultados eram satisfatórios, resultando em imagens transformadas serem desfocadas, ou com os defeitos originais acentuados, especialmente quando o salto era feito a partir de imagens com **DPI** baixo - 100 ou menos [[Lat and Jawahar, 2018](#)]. No entanto, com os avanços na área das redes neurais, em particular na categoria de imagens naturais, modelos como **CNN** [[Wei et al., 2018](#)], [[Lat and Jawahar, 2018](#)] trouxeram uma nova forma treinar algoritmos para tratar imagens de forma adaptativa e com resultados muito melhores do que os algoritmos bem estabelecidos para este problema. Um dos pontos negativos deste tipo de redes é que a criação de datasets de treino é um processo demorado, sendo que para cada imagem de treino (degradada), é necessário uma imagem par com o resultado ideal para validação do resultado. Adicionalmente estes datasets têm de ter casos com características dispersas o suficiente para permitir uma boa generalização do modelo. Um outro modelo que tem vindo a emergir são as **GAN** que, invés de utilizarem uma única rede para gerar conteúdo que depois será validado em cada iteração do treino, utilizam duas redes que competem diretamente: a geradora que

tenta transformar imagens de modo a enganar o discriminador, e este que tenta entender se a imagem de input é a imagem original ou se foi gerada. [Souibgui and Kessentini \[2022\]](#) propõe um modelo deste género que demonstra a sua superioridade tanto em relação a algoritmos baseados em regras, como de modelos baseados em **CNN**.

As **transformações morfológicas** são compostas por vários métodos e propósitos diferentes, nem sempre com o intuito de melhorar a qualidade da imagem, mas para acentuar certas características desta. Por exemplo, técnicas como a dilatação podem ser utilizadas para acentuar regiões de texto de forma a ser possível separar o texto do resto. Por outro lado, técnicas de deteção de arestas, erosão ou *thinning*, diminuem o tamanho dos elementos da imagem, podendo simplificar os caracteres, tornando o seu reconhecimento, ou das suas características (como loops) mais evidentes [[Dey et al., 2022](#)].

Estes diferentes tipos de tratamento podem, na grande maioria dos casos, complementar-se mutuamente e, é costume - inclusive nos estudos referenciados - a criação de pipelines de pré processamento que aplicam estes vários tratamentos de forma sequencial. No entanto, como estes diferentes tratamentos impactam diretamente os dados de input para reconhecimento, nem sempre são benéficos e têm de ser escolhidos com cuidado consoante o estado do sujeito. [Bui et al. \[2017\]](#) demonstra precisamente isto mostrando, por exemplo, que a aplicação de um filtro Gaussiano para a redução de ruído num caso de teste reduziu a taxa de acerto do Tesseract para menos de 1 terço comparado ao resultado sem pré processamento. Isto naturalmente dificulta a criação de pipelines automáticas de pré processamento. Nesse mesmo estudo, é proposto o uso de uma **CNN** que, consoante um número limitado de classes que representam combinações de técnicas de pré processamento, decide a melhor para uma dada imagem. Esta solução resultou numa melhoria considerável, principalmente para o reconhecimento do Tesseract e, mais interessante, a tendência para certas combinações de técnicas com: binarização escolhida 90% das vezes, redução de ruído 35% e acentuação de contrastes 34%. Como mencionado anteriormente, os avanços no tratamento de imagem com uso de modelos de Deep Learning vêm trazer, quando suficientemente generalizados, um método ubíquo para a realização destes vários tratamentos de forma adaptativa. [Souibgui and Kessentini \[2022\]](#) com a **GAN** proposta, demonstra resultados no tratamento de ruído, focagem, binarização e remoção de *watermarks* excelentes, mesmo tendo em conta que o foco principal do modelo era o aumento da resolução da imagem original.

Métricas de avaliação

No ato de pré processamento, as métricas de avaliação são muitas das vezes subjetivas visto, em geral, se tratar de tratamento de imagem e nem sempre haver uma versão não degradada das imagens dos

documentos. No caso de haver essa versão prística, algumas das métricas mais comuns para testar o tratamento de modelos ou algoritmos são: **PSNR**, que compara o ruído na imagem tratada comparativamente com a original, sendo que valores maiores tendem a significar melhores resultados; e **SSIM**, que tenta ter em conta as similaridades das vizinhanças na imagem, assim como outros aspectos mais relativos a cor e luminosidade, imagens idênticas terão valor 1. Não havendo a possibilidade de testar com uma imagem base, pode-se avaliar o efeito do pré processamento através da variação dos resultados do output ou do pós processamento.

3.3 Pós Processamento para OCR

Na generalidade, o tratamento dos resultados de **OCR** ronda em torno das correções sob o texto resultante. Estas correções procuram corrigir erros ortográficos, texto irreconhecível, ou sem sentido (caracteres lixo ou ruído reconhecido).

Correções a nível dos blocos/caixas que englobam o texto reconhecido, são mais orientadas ao tipo de documento e ao seu contexto e serão analisadas com mais atenção nas secções seguintes.

[Nguyen et al. \[2021\]](#) apresentam um estudo extremamente comprehensivo e extenso sobre o estado da arte e o impacto do pós processamento no texto resultante de **OCR**.

Neste estudo, é apresentado primeiramente a importância deste tratamento de texto, não só para aumentar a qualidade das aplicações que o utilizam, exemplo dado no caso de **NLP**: onde taxas de erro por volta dos 7% podem mostrar reduções na qualidade da análise de sentimento de até 30%; mas também no próprio processo de navegação e procura por documentos transcritos por **OCR**: em alguns exemplos os erros de texto não permitiram uma indexação ou reconhecimento de termos de pesquisa correta, não sendo devolvidos na procura.

Os dois principais erros de texto reconhecido são:

- **não palavra** : quando uma palavra reconhecida pelo motor de **OCR** não se encontra no léxico conhecido
- **palavra real** : a palavra reconhecida pertence ao léxico conhecido, porém difere da **ground truth**

Entre estes dois tipos de erro, o primeiro é consideravelmente mais fácil de detetar e potencialmente corrigir, visto o segundo necessitar de informação extra, quer seja esta a **ground truth** do documento - o que é raro -, ou uma análise da palavra dentro do seu contexto.

O estudo segue então para a secção das técnicas de pós processamento. Estas são separadas em dois tipos principais: **manuais** e **(semi-)automáticas**.

As técnicas **manuais** entendem total ação humana e são normalmente dirigidas para projetos mais sensíveis a erros mas que, pela necessidade desta mão de obra, são naturalmente mais custosos, demorados e raros. São casos destes, projetos de transcrição de documentos antigos, como é dado exemplo o projeto da biblioteca nacional da Austrália na correção de jornais históricos. Alguns outros casos destas técnicas descritos servem mais para o propósito de avaliação de algoritmos ou criação de casos de teste.

As técnicas **(semi-)automáticas** podem ser agrupadas em dois tipos: **tratamento de palavras isoladas**, e **dependentes de contexto**. Dentro destas, o tratamento de palavras isoladas é focado na correção de problemas de 'não palavra', enquanto as dependentes de contexto procuram resolver os dois tipos de problemas.

Dentro das diferentes técnicas baseadas nas **palavras isoladas**, algumas características servem como fundamentos dos algoritmos:

- **Léxico conhecido**
- **Confiança do reconhecimento**
- **Frequência de utilização de uma palavra, no documento, ou globalmente**
- **Similaridade da palavra errada com as conhecidas no léxico**

Entre algumas destas técnicas, são realçadas:

Junção de Outputs de OCR

A junção de outputs de OCR visa a escolher entre diferentes resultados para uma dada sequência de palavras, com características distintas (nível de confiança no reconhecimento, quantidade de erros,etc.), e escolher dentro destas ou numa sua mistura, o output final.

Numa 1º fase, os outputs são então obtidos, onde para isto várias propostas foram feitas, com as principais sendo:

- Usando o mesmo motor OCR, fazer vários reconhecimentos de um mesmo trecho de texto
- Usando o mesmo motor OCR, fazer vários reconhecimentos de um mesmo trecho de texto, com parâmetros diferentes ou tratamento de imagem diferente
- Usando múltiplos motores OCR, fazer vários reconhecimentos de um mesmo trecho de texto

Numa 2º fase, estes diferentes outputs têm de ser alinhados de forma a poderem ser comparados palavra a palavra. Para isto, algoritmos sob grafos são comuns.

Por último, utilizando um decisor, o output final é escolhido. Este decisor pode tomar várias formas como: modelos de votação, cálculo de similaridade com léxico, modelos [LSTM](#).

Embora esta técnica geralmente resulte em resultados melhores do que o reconhecimento simples, exige um maior gasto computacional, assim como do facto de estar limitado ao dicionário conhecido.

Vias lexicais

Uma outra visão sobre o tratamento do texto, é na procura das palavras mais similares à não palavra detetada e, dentro destas, decidir qual a que tem maior potencial para a substituir. Este cálculo de similaridade pode ser realizado de várias formas, sendo das mais comuns: a distância de Levenshtein, onde se calcula o número de operações mínimas - inserção, remoção ou substituição - a realizar numa palavra para obter outra; variações deste algoritmo; e distância entre n-gramas, que envolve a quantidade de conjuntos de palavras em comum entre as duas palavras comparadas.

Como no caso anterior, estas vias continuam limitadas pelo léxico conhecido, sendo que muito do estudo é dedicado à criação de dicionários mais abrangentes ou adaptados ao documento, ex.: pegando em palavras chaves do documento ou de um tema e criar um dicionário com as páginas mais relevantes de uma pesquisa feita sobre estes.

Modelos de erro e Máquinas de estado finitas com pesos

Os modelos de erro procuram calcular as probabilidades sob as operações nos caracteres da palavra errada e, a partir destes e do léxico conhecido, decidir qual o melhor candidato para substituição.

Estes modelos de erro podem ser complementados por máquinas de estados finitas com pesos. Os modelos de erro são utilizados para a escolha de candidatos para substituir o erro, e os pesos da máquina são dependentes de características entre os candidatos e a palavra errada como: comprimento, semelhança, entre outras.

Modelos de linguagem baseados em tópicos

No decisão de candidatos para substituição da palavra errada, outros trabalhos sugeriram o uso de contexto do documento de forma parcial, i.e. calcular o tópico do documento a partir da análise deste e utilizar esta informação como um variável extra nas fases de decisão de candidatos. Assim, palavras que sejam numa perspetiva global mais raras não serão tão facilmente descartadas como nos métodos anteriores.

Tal envolve no entanto um processo de decisão sobre quais os tópicos que existem, e a adaptação do léxico para criar correspondências entre as palavras e estes dados tópicos.

Dentro dos métodos **dependentes de contexto**, são notados os ramos:

Modelos de linguagem

Partindo como base os modelos anteriormente descritos, complementam os modelos com o cálculo da probabilidade de distribuição de sequências de palavras, sendo estas parte do documento. Assim, para cada palavra, utilizando os seus vizinhos, será calculada a probabilidade daquela sequência ocorrer. Este cálculo pode ser calculado utilizando léxicos já definidos, ou complementando estes com as frequências dos n-gramas de palavras dentro do documento. Estes modelos caem dentro do ramo estatístico.

Um outro tipo é conseguido através de redes neurais que a partir do texto criam **word embeddings**, o que permite calcular a similaridade entre palavras tendo em conta as suas características. Com esta habilidade, as sequências de palavras do texto reconhecido podem ser sujeitas ao cálculo da probabilidade de ocorrerem e, caso este seja muito baixo, poderá ser sinal de um erro de palavra real.

Machine Learning baseado em características

Neste caso, o contexto é utilizado dentro de uma quantidade de características mais limitado mas também mais robusto do que na alternativa anterior. Algumas destas características tendem a ser:

- Frequência da palavra - nos casos de treino e no próprio documento
- Frequência dos n-gramas com a palavra - nos casos de treino e no próprio documento
- Peso de confusão - conseguido através dos casos de treino
- Confiança do motor OCR na palavra

Seq2Seq - Sequência para Sequência

Esta alternativa, tem como noção que este problema de correção é uma questão que pode ser resolvida por tradução máquina, correspondendo à transformação numa sequência de palavras, numa outra idêntica ou semelhante, na mesma linguagem.

Estes modelos, ao contrário dos mencionados de modelos de linguagem - que recebendo uma sequência de palavras analisavam a probabilidade de uma outra ser a próxima na sequência, ou sugeriam a próxima palavra -, recebem uma sequência de palavras e devolvem também uma sequência de palavras.

O estudo termina com uma análise das tendências destas diferentes áreas, onde se pode notar uma aderência maior para tecnologias de inteligência artificial, juntamente com a tendência para a união dos dois ramos de tratamento de texto (semi-)automático nas soluções.

Métricas de avaliação

Como acontece no caso do pré processamento, o pós processamento necessita de uma **ground truth** para poder ser avaliado. Contra esta, diferentes medições podem ser feitas, como a percentagem de caracteres ou palavras totais nos dois textos, ou a taxa de acerto tendo em conta alinhamento dos textos. Algumas características como a quantidade de *whitespaces* e indentação também podem ser relevantes para certos tipos de documentos. A quantidade de substituições realizadas, mais propriamente de palavras não reais, também pode ser importante para avaliar o software de reconhecimento, embora este erro possa ser resultado de um léxico não apropriado para o documento, ex.: documentos históricos.

3.4 Segmentação de documentos

A segmentação de documentos é um processo que visa decompor o documento nas suas várias secções ou elementos. A sua aplicação pode variar dependendo do objetivo concebido: separação do texto de elementos não texto, retirando informação prejudicial para **OCR**; divisão do conteúdo do documento em várias secções para que possam ser analisadas ou extraídas isoladamente. Por este mesmo motivo, este processo tem aplicabilidade tanto antes como depois de feito o reconhecimento de texto.

[Eskenazi et al. \[2017\]](#) faz um estudo comprehensivo sobre as diferentes metodologias de segmentação de documentos, apresentando as suas diferentes características, evolução e tendências. As diferentes técnicas podem ser divididas de forma comum como:

- **top-down** : divisão a partir da página em blocos mais pequenos
- **bottom-up** : a partir de uma escala mais pequena, ex.: pixels, componentes conectadas; os elementos são aglomerados em conjuntos maiores até completar a página
- **híbrido**

O estudo decide invés seguir por uma divisão em 3 grupos de acordo com a evolução da capacidade dos algoritmos de segmentar diferentes tipos de documentos.

- **Dedicado a um esquema (layout) específico**

- **Capaz de lidar com layouts descritos por um conjunto de parâmetros**
- **Layout potencialmente não restrito**

Algoritmos dedicados a um layout específico

Estes algoritmos, têm como objetivo a segmentação de um dado tipo de esquema. Estes tendem a ser mais rápidos e, embora os menos versáteis, apresentam para o seu tipo de alvo resultados difíceis de superar. Dentro destes, existem 3 ramos principais de algoritmos.

O primeiro, são os algoritmos que assumem as características do esquema e, usando estas, criam gramáticas que os descrevem, ou criam perfis do esquema que são projetados nas imagens de input para aplicação de heurísticas de alinhamento e análises probabilísticas para deteção de erros ou desalinhamentos

O segundo ramo, foca-se no uso de filtros para realce de regiões de um layout. Estes são normalmente utilizados para documentos em que as linhas do texto sejam retas e horizontalmente alinhadas. Os casos mais frequentes destes algoritmos aplicam morfologias, como sequências de erosão e dilatação de forma a identificar imagens, ou Run-Length Smoothing para a formação de manchas em áreas densas com conteúdo.

O último ramo, investiga cálculo das linhas que delimitam uma página de forma que uma segmentação em blocos ocorre naturalmente. Exemplos deste passam pela transformação das linhas do texto em linhas retas; criação de linhas delimitadores através do espaço em branco no documento; transformação de Hough para deteção de linhas.

Algoritmos que usam parâmetros para descrever um layout

Estes algoritmos são mais flexíveis na sua capacidade em lidar com diferentes tipos de documento do que o grupo anterior. Este grupo trabalha com um conjunto de características dos elementos do documento, permitindo assim, com o uso deste contexto extra, mais versatilidade para lidar com irregularidades. Também este grupo pode ser dividido em alguns ramos.

O mais comum destes é o *clustering* onde, partindo de elementos base, como componentes conectadas, procura criar agrupamentos destes, representantes de elementos de ordem superior, como por exemplo imagens, segundo um conjunto de características destes elementos base: geométricas, de textura (distribuição dos pixels), cor, vizinhança, etc.. Algoritmos híbridos também são usuais, como o uso da informação de uma primeira segmentação em blocos antes de partir para o clustering.

Um outro ramo, trata de fazer o agrupamento de elementos no documento original a partir da otimização de funções de custo. São exemplos destes, algoritmos que iteram sobre a realização de segmentação numa página, onde se estima se a realização de novas segmentações diminui o custo da função.

Por último, e segundo mais popular, estão os algoritmos de classificação. Estes, a partir de um grupo de classes predefinido, pretende atribuir uma delas aos elementos do documento. Este ramo, ao contrário do clustering, é marcado por todos os algoritmos necessitarem de treino. Vários trabalhos deste género, realizam um processo inicial de decisão das melhores features utilizando **ML**.

Algoritmos para segmentação de layout potencialmente não restringidos

As técnicas mais recentes de segmentação estudadas em [Eskenazi et al. \[2017\]](#), englobam um leque de projetos de junção de algoritmos antigos de forma híbrida ou combinada, e algoritmos utilizando redes neurais. Estes últimos são pouco abordados neste estudo, mas trabalhos recentes, não apenas na segmentação de documentos, mas também em termos de segmentação de imagem, tendem para a utilização de **CNN**. Exemplo deste é [He et al. \[2017\]](#), que usa múltiplas redes convolucionais para a segmentação de uma página entre texto e não texto, e dentro do não texto em figura ou tabela.

3.5 Trabalho relacionado

Nesta secção serão estudados trabalhos cujo objetivo, ou orientação, se assemelha com os objetivos deste projeto, sendo portanto casos de estudo e inspiração relevantes. Os temas abordados são: extração de conteúdo de jornais ([3.5.1](#)), e cálculo de ordem de leitura ([3.5.2](#)). Uma última secção é aberta para trabalho futuro que se mostre complementar ao projeto.

3.5.1 Extração de conteúdo de jornais

Como argumentado no primeiro capítulo, um dos tipos de documentos que mais sofre no processo de reconhecimento de texto são os jornais. Tal deve-se ao facto de estes terem estruturas complexas, interpoladas com imagens, anúncios, elementos de texto chamativos, porções de texto em contentores irregulares, e outros elementos invulgares que dificultam a criação de heurísticas ou treino de modelos para a sua análise e tratamento.

Nesta secção será feita uma análise de diferentes trabalhos na área de segmentação e extração de conteúdo de jornais. O objetivo da segmentação é geralmente o isolamento dos artigos do jornal.

Estes trabalhos podem ser divididos em dois tipos principais: baseado em **heurísticas**, ou utilizando

modelos de machine e deep learning, maioritariamente **CNN**.

Heurísticas

[Chaudhury et al. \[2009\]](#) foi um projeto proposto por elementos da Google que, embora não tão recente como outros, oferece uma visão sobre heurísticas generalizadas para uma grande quantidade de data. Neste trabalho, a parte relevante do processo, i.e. depois da obtenção da imagem do jornal, passa primeiro por um tratamento da imagem, utilizando uma binarização local baseada em morfologias para reconstrução de gradiente cinzento, o que permite a identificação de um contraste entre o conteúdo do documento e o fundo, e consequentemente saturar o fundo. Em seguida, é realizada uma segmentação em blocos através das linhas e "valetas- trechos do fundo que separam o texto. Depois, é realizada uma análise dos blocos para fazer uma classificação entre títulos e texto considerando o tamanho de fonte e proporção da área do bloco. Os títulos são considerados iniciadores de artigos. Por último, é feita o agrupamento dos blocos em artigos através de duas regras principais: título comum, onde blocos por baixo de um mesmo título fazem parte do mesmo artigo; bloco órfão, onde as exceções à regra anterior são tratadas, juntando blocos órfãos a blocos não órfãos que não tenham blocos por baixo deles e tenham a margem de baixo abaixo da sua margem superior.

O artigo admite acertos de 90% porém, não suporta estes resultados com números de casos de teste ou identificação de um dataset. Além disso, esta segmentação não tem em conta elementos não texto nos jornais.

[Chathuranga and Ranathunga \[2017\]](#) apresenta uma outra proposta focado numa primeira segmentação da página utilizando linhas calculadas através de tratamento de imagem, mas elabora no anterior através de uma extensão destas linhas baseado em regras e uma posterior análise da sua distribuição. Ao contrário do trabalho anterior, as imagens são consideradas na segmentação dos artigos e os resultados são apresentados em conjunto com a informação dos testes.

[Bansal et al. \[2014\]](#) propõe um método híbrido em que são utilizadas heurísticas e grafos para extração do contexto dos blocos, que depois serão classificados usando regressão. Como usual, começam com uma primeira fase de tratamento de imagem para a limpar - binarização, remoção de delimitadores, separar texto de figuras -, e segmentar os blocos em texto e não texto. Numa segunda fase, para cada bloco é calculada a sua vizinhança, sendo que esta é calculada de acordo com um limite de profundidade de adjacência. Para a classificação de blocos e classificação de artigos a profundidade por eles usada

é diferente, sendo superior no caso dos artigos. Por fim, os artigos são classificados através de um modelo que tem informação da sua vizinhança, assim como características geométricas do bloco. Este grafo é denominado de modelo hierárquico de ponto fixo. [Chathuranga and Ranathunga \[2017\]](#) sugerem uma variação deste modelo utilizando um modelo de Markov de 2 dimensões que permite a retenção de possíveis ordens de leitura como contexto adicional.

Inteligência artificial

[Almutairi and Almashan \[2019\]](#), [Meier et al. \[2017\]](#), [Barman et al. \[2021\]](#) demonstram o poder das **CNN** em tarefas de segmentação, sendo capazes de generalizar problemas como linguagens não ocidentais e blocos de conteúdo não retangulares. Esta última habilidade é conseguida através da aplicação de máscaras ao nível dos pixels invés dos blocos. Além da capacidade de extração de características (visuais) destes modelos, dependendo da sua arquitetura, eles podem ser treinados para realizarem técnicas de tratamento de imagem diretamente [[Meier et al., 2017](#)]. [Barman et al. \[2021\]](#) complementa a arquitetura das **CNN** mais genéricas, com a capacidade de analisar características sobre o contexto dos blocos através da modificação da arquitetura para computar **word embeddings** do texto reconhecido.

Por último, é importante realçar o esforço do projeto Europeana [[Europeana](#)] na educação e incentivo sobre o processo de digitalização de jornais históricos utilizando **OCR**.

3.5.2 Ordem de leitura

No sentido de permitir outras estratégias de extração de conteúdo, passando pela reorganização deste à partida, ou das segmentações resultantes deste, esta secção irá abordar algumas estratégias de cálculo da ordem de leitura.

Na maioria dos documentos, considerando linguagens e estruturas que partilhem as características do português, a ordenação de leitura é relativamente trivial, podendo ser feita uma ordenação topográfica com base em regras geométricas simples como: um bloco está antes dos blocos diretamente por baixo dele; um bloco está antes de blocos à sua direita. Tal não é o caso para documentos que utilizam estruturas mais complexas, ou o contexto do conteúdo como guia da sua ordem de leitura, como jornais, revistas, tabelas, etc.

Este é um problema que está inherentemente ligado ao processo de segmentação de páginas, visto que este último é que provisionará os elementos que depois têm de ser organizados numa ordem de leitura. Dependendo da granulação da segmentação, múltiplos algoritmos de cálculo da ordem de leitura

podem ser aplicados para cada nível, como seria o caso de ordenar os diferentes artigos num jornal, e posteriormente ordenar dentro de cada artigo os seus blocos de conteúdo.

[Breuel \[2003\]](#) propõe um algoritmo generalista para o cálculo da ordem de leitura de documentos, utilizando um ordenação topológica dos blocos com apenas duas regras: um bloco *a* está antes do bloco *b* se ambos estiverem horizontalmente alinhados (coordenadas x mais à esquerda e mais à direita sobrepõem-se nos dois blocos, tendo em conta uma certa folga) e *a* está acima de *b*; *a* está antes de *b* se *a* estiver completamente à esquerda de *b*, e não houver nenhum elemento verticalmente entre *a* e *b* que no seu comprimento englobe os dois. Nesta proposta, eles trabalham com blocos ao nível das linhas de texto, porém seria aplicável para blocos de segmentos de texto. Em termos de implementação e lógica, a proposta é bastante simples e competente na generalidade dos casos, porém, como mencionado na introdução da secção, a falta de consideração sobre o contexto impede que certos conflitos entre potenciais ligações de blocos sejam resolvidos da maneira correta.

Bandas desenhadas, tal como jornais, possuem uma estrutura muito variável na sua disposição, mas também na ordem de leitura correta, intendendo por vezes proporcionar experiências ou emoções ao leitor através do modo como o conteúdo é apresentado. São portanto, um bom caso de estudo para o tratamento de jornais. [Kovanen and Aizawa \[2015\]](#) implementaram um algoritmo dedicado a este mesmo tipo de entretenimento. A base da solução definida é o uso de grafos e a sua ordenação. Estes são usados para realizar duas ordenações diferentes, uma primeira sob os diferentes painéis de uma página, e um segundo sob as caixas de texto na página. O método de ordenação é simples, sendo novamente geométrico, usando o vizinho mais próximo. Esta simplicidade, é compensada tanto com uma segmentação que é proposta por eles e dedicada a este tipo de documento, e também pela dupla ordenação que, para cada caixa de texto, limita a quantidade de candidatos disponíveis de acordo com a ordem calculada dos painéis.

Numa abordagem não heurística, [Quirós and Vidal \[2021\]](#) utilizam **ML** para ordenação de documentos históricos com estrutura simples e regular, mas que incluem anotações no canto das páginas que alteram a ordem de leitura do texto, tornando-a mais irregular. A proposta passa pelo cálculo da probabilidade entre pares de blocos, que representam a sua hierarquia, por parte de um Multi Layer Perceptron. Embora os resultados sejam notáveis na generalidade do dataset proposto, eles notam dificuldades para páginas compostas por tabelas, onde a estrutura é mais complexa. Isto deve-se principalmente ao facto de estas serem uma minoria nos dados de treino. Realça-se aqui a possibilidade de adaptar este, e similares métodos de modelos inteligentes, a partir da criação de datasets dedicados a certos tipos de documentos.

3.6 Outros

Esta secção fica em aberto na perspetiva de permitir o complemento do trabalho com outras abordagens que se tornem aparentes mais tarde e, em especial, para o objetivo secundário listado na secção [1.2](#), onde é proposta uma ferramenta para criação de dicionários entre várias versões de uma linguagem.

3.7 Conclusões

O estudo realizado para a produção deste capítulo, permitiu uma clarificação das bases relativas ao trabalho com motores de **OCR**, as boas práticas e procedimentos comuns no seu tratamento e melhoria, e os efeitos que, em especial, pré processamento de imagens e pós processamento de texto podem ter sob o resultado final. Além disso, na secção [3.5](#), o estudo de trabalhos com temática similar ou sobre técnicas relevantes para o projeto atual, permitiu uma melhor percepção sobre os fluxos da solução destes e, simultaneamente, entender os maiores desafios com que se deparam - solucionados e por solucionar. Além disso, realça-se que tal como em várias outras áreas tecnológicas, tem nos últimos anos havido uma imergência de soluções com recurso a Inteligência Artificial, com principal sucesso no ramo de tratamento de imagem.

O acumular deste estudo permitiu então um desenho da solução final e do plano de tarefas mais coerente, e fundado nos produtos e evolução da área em que se insere, i.e. reconhecimento óptico de caracteres para extração de conhecimento.

Capítulo 4

OSDOCR Filsofia

Neste capítulo é realizada uma reflexão sobre o problema e as consequentes propostas que são deste retiradas. Serão descritas decisões e modelos fundamentais da solução, assim como a arquitetura desta.

4.1 O problema

Na sua essência, o problema abordado pode ser descrito como a aquisição de resultados não satisfatórios na aplicação de OCR sob documentos antigos com texto estruturado.

Como se analisou no capítulo 3, estes resultados podem ser melhorados através de múltiplas interações em múltiplas partes do processo do reconhecimento de texto: quer seja antes deste ser realizado, através de processamento de imagem; durante a deteção de texto, através da configuração proposta ao motor OCR; ou após através do tratamento dos resultados e do texto.

Estas diferentes interações são, na generalidade, aplicações sobre um input inicial de forma a transformá-lo, consequentemente resolvendo particularidades deste. Exemplos disto são: aplicação de técnicas de binarização que reduzem ruído ou imperfeições numa imagem; melhoria de resolução de uma imagem; correções ortográficas de texto; etc. Estas interações, podem então ser consideradas como um conjunto de ferramentas que podem ser aplicadas ao input do nosso problema de forma a abordar diferentes defeitos deste de acordo com as suas características; até porque, como também foi descrito para algumas destas, a sua utilização indiscriminada pode deteriorar, ao invés de melhorar, o produto final. As ferramentas comumente utilizadas não são explicitamente dedicadas ao problema de OCR em concreto, aumentando a sua utilidade e adaptabilidade para outras situações. Tal reforça o intuito base do trabalho, da criação de um toolkit que proporcione um conjunto de funcionalidades independentes, com a intenção final de procurar melhorar os resultados da transcrição de texto.

Podemos então declarar aqui uma primeira proposta:

Proposta 1: A solução para o problema deve ser composta por um conjunto de ferramentas independentes, i.e. um toolkit.

Durante a análise do estado da arte, notou-se que para soluções para o problema de melhorar a aplicação de OCR, um processo com 3 partes principais pode ser identificado, sendo estas: pré-processamento de OCR, composto por processamento do input para realização de OCR, usualmente uma imagem; OCR, configurando o motor de OCR de acordo com as características do input, como a linguagem esperada do texto ou o dpi da imagem; pós-processamento de OCR, aplicando transformações nos resultados como, remover blocos de ruído, ordenar blocos identificados ou aplicar correções no texto.




Figura 2: Aplicação de OCR com passos para melhoria de resultados

Observando a figura 2, podemos identificar que a estrutura das soluções para aplicação de OCR é uma pipeline.

Estas pipelines podem ser elaboradas como uma sequência de aplicações das ferramentas acima mencionadas, como por exemplo:




Figura 3: Exemplo de pipeline de aplicação de OCR

Assumindo então a proposta da criação de um toolkit, e a necessidade de verificar a eficácia deste e criar casos de uso deste, torna-se claro que será útil o desenvolvimento de uma pipeline de aplicação de OCR, que faça uso do toolkit desenvolvido, assim como de outras ferramentas disponíveis e que abordem questões em falta no toolkit.

Segundo o estudo realizado, esta pipeline será composta por 3 partes principais: pré-OCR, OCR e pós-OCR.

Proposta 2: A solução para o problema deve possuir uma pipeline de aplicação de OCR que faça uso da toolkit desenvolvida.

Proposta 3: A pipeline desenvolvida deve ser composta por 3 partes principais: pré-processamento de OCR, OCR e pós-processamento de OCR.

Como discutido, o uso de ferramentas independentes é interessante devido ao facto que diferentes inputs irão necessitar de tratamentos distintos de forma a obter os melhores resultados. Desta forma, é interessante que a pipeline desenvolvida não seja totalmente sequencial, de modo a aumentar a sua utilidade.




Figura 4: Exemplo de pipeline de aplicação de OCR com blocos opcionais

Proposta 4: A pipeline deverá ser configurável. Permitirá, dentro dos blocos disponíveis, escolher aqueles que são aplicados.

Esta pipeline, seguindo a estrutura explicada de aplicação de OCR, apresentará 3 partes principais onde, a primeira - pré-OCR - irá lidar com um input do tipo imagem e terá como output uma imagem; a segunda - OCR - terá como input uma imagem e devolverá os resultados de OCR; e a última - pós-OCR - irá ter como input os resultados de OCR, e terá como output a transcrição do texto da imagem.

Nota-se uma ambiguidade no output da 2º parte e no input da 3º, os resultados de OCR. Tal, deve-se ao facto de motores OCR, como o Tesseract, permitirem vários tipos de output. É então relevante a criação de um estrutura de dados universal para a representação de resultados OCR.

Como estudado no capítulo 3, tais representações já possuem um standard um formato de ficheiro, como **HOCR**, portanto a estrutura de dados escolhida deve ser baseado nestes, ou ser convertível para o standard.

Proposta 5: Criação de uma estrutura de dados universal para a representação dos resultados de OCR.

Proposta 6: A estrutura de dados universal para a representação dos resultados de OCR deve ser baseada ou convertível num formato standard.

No estudo do estado da arte, foi possível compreender que a criação de algoritmos ubíquos para todos os tipos de documentos é um empreendimento com diminutas chances de sucesso, sendo que para muitos problemas, como por exemplo o cálculo da ordem de leitura, mesmo focando num só tipo de documento como jornais, os resultados podem não ser satisfatórios devido à diversidade de estruturas existentes. Consequentemente, é esperado que a pipeline não seja sempre suficiente na resolução do problema. Deste modo, servindo também como outro caso de uso do toolkit, a criação de uma ferramenta que permite ao utilizador um maior manuseamento dos resultados de OCR é uma proposta para a solução.

Tendo em conta a forte qualidade visual desta área de trabalho, onde se procura processar e analisar imagens de documentos, a utilidade e usabilidade desta ferramenta de edição é elevada ao definirmos que o editor seja gráfico.

Proposta 7: A solução do problema deverá possuir um editor gráfico dos resultados de OCR, que permita aplicar ferramentas propostas pelo toolkit.

Em suma, as propostas definidas para o desenho da solução são:

- 1** A solução para o problema deve ser composta por um conjunto de ferramentas independentes, i.e. um toolkit.
- 2** A solução para o problema deve possuir uma pipeline de aplicação de OCR que faça uso da toolkit desenvolvida.
- 3** A pipeline desenvolvida deve ser composta por 3 partes principais: pré-processamento de OCR, OCR e pós-processamento de OCR.
- 4** A pipeline deverá ser configurável. Permitirá, dentro dos blocos disponíveis, escolher aqueles que são aplicados.
- 5** Criação de uma estrutura de dados universal para a representação dos resultados de OCR.
- 6** A estrutura de dados universal para a representação dos resultados de OCR deve ser baseada ou convertível num formato standard.
- 7** A solução do problema deverá possuir um editor gráfico dos resultados de OCR, que permita aplicar ferramentas propostas pelo toolkit.

4.2 Modelos

Realizada uma acessão mais concreta do problema e das soluções que para este são sugeridas, segue-se uma discussão sobre os elementos fundamentais que servirão como base do trabalho a realizar. No caso deste problema, os de maior relevância são os tipos de dados que serão processados: imagens para processamento e realização de OCR; e estruturas de dados para representação dos resultados OCR.

4.2.1 Imagem

A área de computação de visão é extensa e complexa, apresentando já a sua medida de standards e ferramentas disponíveis. Neste sentido, no propósito deste problema, apenas sobra escolher o tipo de estruturas de dados que se pretende usar de forma a gerar uma consistência no projeto.

Sendo que a componente prática do projeto será maioritariamente produzida utilizando Python, optou-se pela utilização das estruturas de dados oferecidas pelo **open-cv** devido à comprehensiva biblioteca de métodos disponíveis, utilidade para o problema e reputação na área.

4.2.2 OCR Tree - estrutura de dados para resultados OCR

Os resultados de OCR podem tomar múltiplas formas; tomando como exemplo a utilização de Tesseract, este permite a geração de output diretamente no formato de texto, dicionário, pdf, hocr, etc.. Deste modo, é necessário decidir o tipo de formato que se pretende para ser trabalhado pelas ferramentas da solução.

Tendo em conta os tipos de problemas que se pretendem resolver - remover ruído detetado como texto, calcular ordem de leitura, categorizar elementos detetados -, é necessária informação além do texto detetado, sendo útil informações geométricas sobre este ex.: posição na imagem, dimensões de elementos detetados. Deste modo, é útil observar o standard HOCR.




Figura 5: Representação visual dos resultados de OCR armazenados em formato HOCR

Como podemos observar na figura 5, é possível criar uma representação visual dos resultados de OCR a partir de ficheiros HOCR, mais digerível do que o seu formato base. Este tipo de representação disponibiliza uma importante ferramenta de debugging de métodos que transformem os resultados OCR, assim como uma melhor compreensão sobre a natureza dos resultados OCR como uma estrutura de dados do tipo árvore. Esta representação visual é apenas possível devido à informação extra armazenada sobre o texto reconhecido, como as bounding boxes.

A partir deste tipo de ficheiro, temos então que a informação mais relevante que podemos obter é:

- posição e dimensões do texto detetado, através do armazenamento de bounding boxes.
- diferentes níveis de deteção de texto, permitindo uma estruturação base deste.
 - página
 - bloco
 - parágrafo
 - linha
 - palavra
- identificadores dos elementos.
- nível de confiança do texto detetado.

No propósito da criação de uma classe de dados para o papel da estrutura de dados universal para representar os resultados OCR, seguiu-se com um desenho baseado numa árvore, denominada **OCR Tree**, e que irá possuir, como atributos base, os acima listados.

Esta classe irá, para cumprir standards, possuir um conversor de e/para HOCR.

Maior detalhe sobre esta está disponível nos capítulos seguintes, dedicados à implementação da solução.

4.3 Arquitetura da solução

Descritas as decisões fundamentais sobre a solução e os modelos base que a irão compor, expõe-se nesta secção a arquitetura desta, na sua generalidade e das suas partes.

A arquitetura geral da solução é composta por 3 componentes principais, correspondentes às propostas anteriores: o "OSDOCR Toolkit", que será um conjunto de ferramentas desenvolvidas para melhorar os resultados de OCR; a "OSDOCR Pipeline" que será uma aplicação do toolkit, assim como de algumas soluções já existentes, no formato de uma pipeline versátil; "OSDOCR Editor" que será uma segunda aplicação do toolkit, com o intuito de permitir um manuseamento mais delicado dos resultados OCR.




Figura 6: Arquitetura geral da solução

A maioria do código desenvolvido foi utilizando **Python**, com algumas instâncias de **C**.

4.3.1 OSDOCR Toolkit

A componente de OSDOCR Toolkit servirá como base para as outras duas componentes da solução e, como o nome desta indica, servirá como o produto principal a ser importado para projetos futuros.

Esta é composta por 3 módulos fundamentais, cada um dedicado a uma dada área: "Imagen", disponibilizando ferramentas de processamento e análise de imagens de documentos; "OCR Tree", com ferramentas que permitem manipulação de resultados OCR representados pela classe OCR Tree; "Texto", para o processamento de texto e geração de output textual.



Figura 7: Arquitetura OSDOCR Toolkit

4.3.2 OSDOCR Pipeline

A componente de OSDOCR Pipeline é um exemplo de uma aplicação do toolkit criado no caso de uso clássico para a aplicação de OCR. Este apresenta portanto os 3 procedimentos principais deste uso clássico: pré-processamento OCR, tratamento e análise da imagem de input; OCR; pós-processamento OCR, tratamento e interpretação dos resultados.

Como proposto, esta componente torna-se mais útil se tiver um maior nível de versatilidade. Deste modo, mesmo os procedimentos gerais de pré e pós processamento são opcionais, como se pode ver na figura 8.




Figura 8: Arquitetura OSDOCR Pipeline - high level

Como também se pode verificar na figura, os tipos de dados manipulados na pipeline são contidos - havendo apenas 3 tipos usados -, auxiliando a possibilidade de a configurar.

Cada um dos procedimentos é composto por blocos elementares, que, mantendo a mesma lógica de versatilidade, são opcionais.




Figura 9: Arquitetura OSDOCR Pipeline - reduzida

Alguns destes blocos, principalmente no que toca a manipulação de imagem, fazem uso de soluções externas disponíveis, ex.: upscaling de imagem utilizando modelos de Deep Learning open-source.

Maior detalhe sobre estes blocos será discutido no capítulo de implementação da pipeline.

4.3.3 OSDOCR Editor

O OSDOCR Editor é um GUI relativamente simples, sendo que apresenta uma proposta bastante focada, a de manipulação de OCR Tree.

Este segue uma arquitetura **MVC** (Model View Controller), tendo sido desenvolvido a **View** geral utilizando a biblioteca **PySimpleGui**. Para complemento desta, e devido à permitida compatibilidade, foi utilizado **Matplotlib** no desenvolvimento do canvas visualizador e de manipulação da OCR Tree.




Figura 10: Arquitetura MVC

O **controlador** neste GUI provém - para além do Matplotlib e do PySimpleGui - das ferramentas disponibilizadas pelo OSDOCR Toolkit e, nalguns casos como por exemplo de aplicação de OCR numa área focada de uma imagem, da OSDOCR Pipeline.

Os constituintes principais do **modelo** são: imagem de input; OCR Tree; abstrações de OCR Tree, ex.: artigos (lista de listas OCR Tree).

Capítulo 5

OSDOCR Estruturas de Dados - Implementação

Neste capítulo, será descrito em detalhe a implementação dos modelos principais de dados usados na base do projeto. Estes são a estrutura OCR Tree, utilizada para representação de resultados OCR; e a estrutura Box, utilizada maioritariamente para a representação de Bounding Boxes, mas com a particularidade de possuir uma coleção de métodos que permitem a sua manipulação.

5.1 OCR Tree

Como o produto final do projeto intende aceitar diferentes tipos de resultados OCR, i.e. resultantes de diferentes motores OCR ou de ficheiros como hOCR que já possuem os resultados, existe uma necessidade de converter estes diferentes formatos num único tipo que mantenha a informação base pretendida.

Estruturas de dados standard como [HOCR] ou [ALTO] apresentam um resultado final semelhante e com capacidade base de armazenamento de meta-dados superior porém, sendo baseados em XML, tornam a sua manipulação mais complexa e, em múltiplos casos a informação proporcionada é além do necessário ou gera conclusões erradas quando gerado de output automático (ex.: atribuição de classes caption a blocos que são títulos). Assim sendo, embora tenha sido desenvolvido um conversor de, e para HOCR, para o atual projeto, optou-se pela criação de uma estrutura de dados própria.

Deste modo, tomando como inspiração os atributos dos resultados do Tesseract no modo de dicionário [Tesseract], foi implementada uma estrutura de dados no formato de árvore de dados.

A escolha de uma estrutura de árvore permite a hierarquização de blocos de acordo com o seu nível, quer exista uma divisão de nível à partida, como é o caso do Tesseract que segue: página → bloco → parágrafo → linha → palavra; ou apenas um único nível, semelhante ao Keras-OCR.

Todos os algoritmos desenvolvidos, inclusive os métodos para visualização (métodos de debugging e GUI desenvolvido), assumem e trabalham com os dados de OCR no formato desta estrutura de dados.

As características mais relevantes desta estrutura são:

- **Level** : Nível/altura do nodo.
 - documento : 0
 - página : 1
 - bloco : 2
 - parágrafo : 3
 - linha : 4
 - palavra : 5
- **(page|block|par|line|word)_num**: Identificação da ordem (dentro de outras caixas(ex.: linha), se aplicável)
- **text** : Texto do bloco, normalmente apenas preenchido ao nível da palavra
- **conf** : Confiança no texto
- **id**
- **type** : Tipo do bloco, ex.: delimitador, título
- **children**
- **box**: Bounding box do nodo, representado pela estrutura de dados Box, que também possui métodos para transformações e verificações geométricas ou de características.
- Características de texto: ex.: texto iniciado (start_text); texto não terminado (end_text).




Figura 11: Árvore de resultados OCR num documento

Construtores da classe são capazes de admitir outros atributos não base de modo a expandir a utilidade da estrutura. Construtores disponíveis: iniciação por argumentos, dicionário, ficheiro JSON e ficheiro HOCR.

Da mesma forma, conversores para estes ficheiros compreendidos para iniciação também foram desenvolvidos.

A classe possuí por métodos de transformação e análise sobre a árvore OCR que facilitam a manipulação dos resultados OCR.

Segue-se uma lista dos métodos mais relevantes disponíveis da classe.

id_boxes

Descrição: Adiciona identificador aos blocos.

Argumentos:

- level : lista de níveis onde adicionar identificador
- ids (opt): dicionário de ids a utilizar caso não se queira iniciar no 0.
- delimiters (opt): flag para identificar delimitadores
- area (opt): argumento do tipo Box, que restringe os nodos a identificar a uma dada área
- override (opt): flag para reescrever id se já existe.

calculate_mean_height

Descrição: Calcula a altura média das caixas de um dado nível.

Argumentos:

- level : nível a calcular
- conf (opt): valor de confiança de texto no caso de apenas serem relevantes caixas com certa confiança (aplicável apenas para nível de texto)

is_text_size

Descrição: Verifica se um nodo se encontra dentro do tamanho de texto.

Argumentos:

- text_size : tamanho de texto a comparar
- mean_height (opt): altura do bloco, caso já tenha sido calculado
- range : margem de erro aceitável (relativo)
- level : nível das caixas usado caso seja necessário calcular a altura média
- conf : confiança do texto a utilizar para calcular a altura média

is_empty

Descrição: Verifica se um nodo é vazio.

Argumentos:

- conf : confiança de texto a utilizar para considerar palavras válidas
- only_text : flag que diz se o tipo do bloco influencia o resultado, i.e. blocos de tipo "image" não são vazios

text_is_title

Descrição: Verifica se um nodo é potencial título.

Algoritmo: Caixa não é texto vertical e é maior do que o tamanho normal de texto.

Argumentos:

- `normal_text_size` : tamanho de texto considerado como normal
- `conf` : confiança de texto a utilizar para considerar palavras válidas
- `range` : margem de acerto aceitável (relativo)
- `level` : nível usado para calcular o tamanho médio do bloco

is_delimiter

Descrição: Verifica se um nodo é potencial delimitador.

Algoritmo: Caixa já é do tipo delimitador, ou é vazia e segue a regra:

$box.width \geq box.height * 4 \mid\mid box.height \geq box.width * 4$.

Argumentos:

- `conf` : confiança de texto a utilizar para considerar palavras válidas
- `only_type` : flag que dita se usa apenas o tipo do nodo para a verificação

is_image

Descrição: Verifica se um nodo é potencial imagem.

Algoritmo: Caixa já é do tipo imagem ou, é vazia, não é um delimitador e é 3 vezes mais alta do que o tamanho de texto.

Argumentos:

- `conf` : confiança de texto a utilizar para considerar palavras válidas
- `text_size` : tamanho de texto a utilizar para comparação com altura da caixa
- `only_type` : flag que dita se usa apenas o tipo do nodo para a verificação

get_boxes_in_area

Descrição: Obtém todas as caixas numa dada área.

Argumentos:

- area : área de interesse
- level : nível dos nodos a ir buscas. Se nível == -1, obtém todos os nodos
- conf : confiança de texto a utilizar para considerar nodos válidos
- ignore_type : tipos de nodo a ignorar

is_vertical_text

Descrição: Verifica se um nodo é texto vertical.

Argumentos:

- conf : confiança de texto a utilizar para considerar palavras válidas

Algoritmo:

Algorithm 1 Verificação de texto vertical

```

1: if nodo não é vazio then
2:   lines
3:   if len(lines) == 0 then return False
4:   end if
5:   // Linha única
6:   if len(lines) == 1 then
7:     words
8:     // Palavra única
9:     if len(words) == 1 then
10:       if altura da palavra >= 2 * largura da palavra then return True
11:       end if
12:       // Múltiplas palavras
13:     else
14:       // Verifica se a maioria das palavras coincidem horizontalmente
15:       widest_word <- calcula palavra mais larga
16:       overlapped_words = 0
17:       for word in words do
18:         if word == widest_word then
19:           continue
20:         end if
21:         if word.box.within_horizontal_boxes(widest_word.box,range=0.1) then
22:           overlapped_words += 1
23:         end if
24:       end for

```

```

25:     if overlapped_words/len(words) >= 0.5 then return True
26:     end if
27:   end if
28:   // Múltiplas linhas
29: else
30:   // Verifica se a maioria das linhas coincidem verticalmente
31:   tallest_line <- calcula linha mais alta
32:   overlapped_lines = 0
33:   for line in lines do
34:     if line == tallest_line then
35:       continue
36:     end if
37:     if line.box.withinvertical_boxes(tallest_line.box,range=0.1) then
38:       overlapped_lines += 1
39:     end if
40:   end for
41:   if overlapped_lines/len(lines) >= 0.5 then return True
42:   end if
43: end if
44: return False

```

prune_children_area

Descrição: Atualiza dimensões dos filhos de um nodo para se encaixarem dentro de uma área.

Argumentos:

- area : área de interesse

boxes_below (método semelhante para as outras direções)

Descrição: Dada uma lista de OCR Tree, devolve aqueles que se encontram por baixo do bloco atual.

Os blocos filtrados podem intersetar ou estar dentro do bloco comparado.

Argumentos:

- blocks : lista de blocos a filtrar

boxes_directly_below (método semelhante para as outras direções)

Descrição: Dada uma lista de OCR Tree, devolve aqueles que se encontram diretamente por baixo do bloco atual. Blocos filtrados não estão dentro do bloco comparado e não podem estar diretamente por baixo dos outros blocos.

Argumentos:

- blocks : lista de blocos a filtrar

join_trees

Descrição: Junta duas OCR Tree com o mesmo nível numa única árvore. Tem dois métodos principais de junção das árvores: vertical, operação mais simples em que basicamente apenas se juntam as duas listas de ramos dos nodos raiz (assume-se que uma das árvores é mais alta do que a outra e não se intersetam); e horizontal, onde se procura juntar árvores que têm interseção no eixo y, sendo necessário verificar as posições que os filhos devem tomar e se certos filhos devem ser unidos num único (podendo resultar numa junção de linhas).

Argumentos:

- tree : árvore a juntar
- orientation : orientação da junção, vertical ou horizontal.

Algoritmo:

Algorithm 2 Junção horizontal

```
1: tree_children
2: self_children
3: // no último nível, filhos são ordenados da esquerda para a direita
4: if último nível da tree then
5:     tree_children ← ordenar lista da esquerda para a direita
6: end if
7: for child in tree_children do
8:     if não é o último nível then
9:         self_children ← ordena de cima para baixo
10:        if child pode ser inserida no topo ou fundo da lista then
11:            self_children ← insere child no início ou fim
12:        else
13:            // procura slot para inserir, ou nodo com quem unir
14:            joined = False
15:            for i in range(len(self_children)) do
```

```

16:           if child não intersesta com nodo i ou nodo i+1 then
17:               self.children ← adiciona child entre os dois nodos
18:               joined = True
19:   ElsIf intersesta com nodo i
20:       if interseção em pelo menos 70% da altura da caixa then
21:           if nodo i tem filhos then
22:               // join recursivo
23:               self_children[i].join_trees(child,orientation=orientation)
24:           else
25:               self_children ← insere child depois do nodo i
26:           end if
27:           joined = True
28:       else
29:           // procura local mais baixo para inserir (por poder intersetar com varios blocos)
30:           for j in range(i,len(self_children)) do
31:               if nodo j mais alto do que child then
32:                   self_children ← insere child depois do nodo j
33:                   joined = True
34:               end if
35:           end for
36:           if not joined then
37:               self_children ← insere child no fim
38:               joined = True
39:           end if
40:       end if
41:   end if
42:   if joined then
43:       break
44:   end if
45:   end for
46: end if
47: else
48:     self.children ← adiciona child no fim da lista
49: end if
50: self.children ← atualiza lista de filhos
51: end for

```

remove_blocks_inside

Descrição: Remove os blocos dentro do bloco com dado id. Blocos removidos são do mesmo nível que o bloco com dado id.

Argumentos:

- id : id do bloco a limpar
- block_level : nível do bloco a limpar

update_position

Descrição: Atualiza a posição da bounding box de um nodo e dos seus filhos. Especialmente útil para o editor OCR.

Argumentos:

- top : valor a atualizar verticalmente
- left : valor a atualizar horizontalmente
- absolute : flag que indica se operação é de tipo absoluta, i.e. bounding box vai ser diretamente atualizada com estes valores, ou relativa, aos valores da bounding box serão somados os argumentos

update_size

Descrição: Atualiza o tamanho da bounding box de um nodo e dos seus filhos nas arestas (filhos interiores não serão alterados). Especialmente útil para o editor OCR.

Argumentos:

- top : valor a atualizar ao topo
- left : valor a atualizar à esquerda
- bottom : valor a atualizar ao fundo
- right : valor a atualizar à direita
- absolute : flag que indica se operação é de tipo absoluta, i.e. bounding box vai ser diretamente atualizada com estes valores, ou relativa, aos valores da bounding box serão somados os argumentos

update_box

Descrição: Atualiza diretamente valor da bounding box do nodo e dos filhos. Especialmente útil para o editor OCR.

Argumentos:

- top : valor a atualizar ao topo
- left : valor a atualizar à esquerda
- bottom : valor a atualizar ao fundo
- right : valor a atualizar à direita
- children : flag que indica se é para se aplicar ajuste direto no nodo, ou apenas ajustar de forma a não sair da bounding box do pai.

scale_dimensions

Descrição: Escala dimensões da bounding box do nodo e dos seus filhos. Especialmente útil para o editor OCR.

Argumentos:

- scale_width : escalar de valores do eixo horizontal
- scale_height : escalar de valores do eixo vertical

5.2 Box

A estrutura de dados Box é utilizada maioritariamente para encapsular os dados das bounding boxes dos resultados de OCR. Embora em geral este tipo de dados seja geralmente fornecido por métodos de módulos de manipulação de imagens na forma de tuplo, a utilização de uma classe dedicada permite o desenvolvimento e utilização de métodos para sua manipulação de forma mais simples e organizada.

Tal como a estrutura de dados OCR Tree, esta classe apresenta construtores e conversores de ficheiros diferentes tipos: argumentos simples, dicionário, ficheiro JSON.

Os principais atributos da estrutura são:

- **left** : Valor mais à esquerda da caixa.
- **right** : Valor mais à direita da caixa.
- **top** : Valor mais em cima da caixa (menor do que bottom por ser baseado em manipulação de imagem).

- **bottom** : Valor mais em baixo da caixa.
- **width** : Comprimento da caixa.
- **height** : Altura da caixa.

Realça-se que os atributos desta classe são esperados no formato de inteiros, devido a ter como foco o seu uso no contexto do espaço de imagens.

Segue-se uma lista dos métodos mais relevantes disponíveis da classe.

update

Descrição: Atualiza os valores dos atributos de posição da caixa. Atributos de posição são mantidos válidos, i.e. $\text{left} \leq \text{right}$ e $\text{top} \leq \text{bottom}$. Altura e comprimento são atualizados automaticamente.

Argumentos:

- top : valor a atualizar ao topo
- left : valor a atualizar à esquerda
- bottom : valor a atualizar ao fundo
- right : valor a atualizar à direita

move

Descrição: Soma valores aos atributos de posição da caixa.

Argumentos:

- x : valor a somar nos atributos de posição horizontais
- y : valor a somar nos atributos de posição verticais

within_vertical_boxes (método semelhante para direção horizontal)

Descrição: Verifica se caixa e caixa a ser comparada estão alinhadas verticalmente, podendo considerar uma margem de acerto. Verificação é realizada nos dois sentidos, i.e. caixa 1 alinhada com caixa 2 ou vice-versa.

Argumentos:

- box : caixa a comparar
- range : valor relativo da altura da caixa, a servir como margem para considerar na verificação

is_inside_box

Descrição: Verifica se caixa a ser comparada está dentro da caixa. Caixa a ser compara tem de estar completamente dentro para resultado afirmativo.

Argumentos:

- box : caixa a comparar

intersects_box

Descrição: Verifica se caixa a ser comparada interseca com a caixa.

Argumentos:

- box : caixa a comparar
- extend_vertical : flag para indicar se verificação deve ser feita apenas longo do eixo x (ex.: utilizado para verificar se caixa comparada está diretamente por acima da caixa)
- extend_horizontal : flag para indicar se verificação deve ser feita apenas longo do eixo y (ex.: utilizado para verificar se caixa comparada está diretamente à direita da caixa)
- inside : flag para indicar se verificação de caixa dentro conta como interseção

intersect_area_box

Descrição: Calcula a caixa de interseção entre a caixa e uma caixa a comparar.

Argumentos:

- box : caixa a comparar

remove_box_area

Descrição: Remove área da caixa. Procura remover área aplicando as menores modificações possíveis. Apenas realiza modificações, se área fornecida está dentro da caixa.

Argumentos:

- area : área da caixa a remover

get_box_orientation

Descrição: Método naive para obter orientação da caixa (horizontal, vertical ou square) de acordo com a diferença entre a sua altura e comprimento.

join

Descrição: Une duas caixas.

Argumentos:

- box : caixa a unir

distance_to

Descrição: Calcula distância entre duas caixas. Procura dois pontos mais próximos de acordo com argumentos dados e utiliza distância euclidiana para calcular a distância.

Argumentos:

- box : caixa a comparar
- border (opt): borda da caixa a ter em conta. Valores disponíveis: "left", "right", "top", "bottom", "closest". Se "closest" for fornecido, procura a menor distância entre bordas. Se nenhum valor for fornecido, utilizado os pontos centrais das caixas.

distance_to_point

Descrição: Calcula distância entre a caixa e um ponto. Procura calcular a menor distância da caixa ao ponto (tendo em conta a diferença entre o ponto e as bordas).

Argumentos:

- x : valor x do ponto
- y : valor y do ponto

vertices

Descrição: Retorna uma lista dos vértices da caixa na forma de tuplos (x,y) seguindo de cima para baixo, esquerda para a direita.

closest_edge_point

Descrição: Calcula a borda mais próxima entre a caixa e um ponto. Utilizado no editor de resultados OCR para operações de divisão de blocos.

Argumentos:

- x : valor x do ponto
- y : valor y do ponto

Capítulo 6

OSDOCR Toolkit - Implementação

Neste capítulo será discutida a componente de Toolkit, premissa base do tema da dissertação. Esta componente consiste num conjunto de ferramentas focado na melhoria dos resultados obtidos da aplicação de **OCR** em documentos antigos, com especial interesse em jornais.

Estas ferramentas são então pertinentes para os diversos passos do processo convencional de **OCR**, i.e. pré-processamento, OCR e pós-processamento; atendendo tanto a processamento de imagem, processamento de resultados de OCR e texto, e validação de resultados.

6.1 Sumário

- Processamento de resultados [OCR 6.2](#)
 - Conversão de resultados [OCR 6.2](#)
 - Debugging [6.2](#)
 - Análise de texto [6.2](#)
 - Limpeza de OCR Tree [6.2](#)
 - Categorização de Blocos [6.2](#)
 - Divisão de blocos [6.2](#)
 - Cálculo de ordem de leitura [6.2](#)
 - Segmentação de resultados [6.2](#)
- Processamento de imagem [6.3](#)
 - Correção de ângulos de rotação
 - Corte de sombra nas margens
 - Binarização de imagem
 - Identificação de delimitadores

- Identificação de imagens no documento
- Segmentação de documento
- Processamento de texto [6.4](#)
 - Limpeza de hifenização
 - Geração de output

6.2 Processamento de resultados OCR

O resultado da aplicação de OCR em imagens de baixa qualidade ou complexas como é o caso de jornais, é na generalidade propício a um output ruidoso e com vários defeitos em diferentes níveis, quer seja nas bounding boxes dos blocos, texto reconhecido com erros, ruído reconhecido como texto, blocos que deveriam ser separados, etc.

Deste modo, surgiu a oportunidade de adicionar ao *toolkit* funcionalidades que fossem capazes de abordar estes problemas.

Esta secção trata particularmente de funcionalidades aplicadas sobre os resultados de OCR, i.e. após a aplicação de reconhecimento de caracteres, não tendo influencia no input desse procedimento.

Conversão de resultados OCR

Como base para a manipulação dos dados, como mencionado anteriormente, foi utilizada a estrutura de dados OCR Tree. Consequentemente, um conjunto de conversores desta classe foram desenvolvidos, nomeadamente:

- JSON : de e para JSON. Inspirado no output de Tesseract para dicionário.
- HOCR : de e para HOCR. Standard para armazenamento de dados resultantes de OCR.
- Texto : para texto.
- MD : para markdown.

Debugging

Uma das características fundamentais de OCR é a sua capacidade para visualização fácil de resultados. Uma das mais úteis ferramentas de debugging geradas foi a reconstrução da OCR Tree sobre a imagem original.

draw_bounding_boxes

Descrição: Desenha blocos de OCR Tree sob uma imagem.

Argumentos:

- ocr_results : OCR Tree com os blocos a desenhar
- img : imagem a ser modificada
- draw_levels : lista dos níveis de nodos a desenhar
- conf : confiança mínima de texto dos blocos de nível de texto a desenhar
- id : flag para desenhar id do bloco, caso disponível

Outros métodos, mais circunstanciais, criados são para o desenho do template de um jornal e de artigos respetivamente.

draw_journal_template

Descrição: Desenha o template de um jornal sob uma imagem.

Argumentos:

- journal_data : dicionário com entradas dos segmentos de um jornal (header, columns, footer). Cada um com um objeto do tipo Box que dita a bounding box do elemento. No caso das colunas é uma lista de Box.
- img : imagem a ser modificada

draw_articles

Descrição: Desenha artigos sob uma imagem.

Argumentos:

- articles : lista de listas de OCR Tree. Assume-se que cada lista de OCR Tree é um artigo. Cada OCR Tree será um nodo de nível 2
- img : imagem a ser modificada

Análise de texto

A análise de texto dos resultados OCR permite inferir características sobre o documento que não estão à partida disponíveis na OCR Tree. Foi desenvolvido um conjunto de métodos que cada um infere uma das seguintes métricas a partir da OCR Tree principal:

- Tamanho de texto normal : método **get_text_sizes**
- Espaçamento médio de palavras : método **analyze_text**
- Colunas do documento : método **get_columns**

Todas estas métricas podem ser obtidas na chamada do método **analyze_text**.

Naturalmente, a qualidade do cálculo destas métricas irá depender da qualidade dos resultados OCR, ou no caso de análise de texto, do nível de confiança de texto usado.

Os métodos **get_text_sizes** e **get_columns** são ambos baseados em análise de frequências e procura de picos na curva destas.

get_text_sizes

Descrição: Analisa as frequências dos tamanhos de linha, pesados pelo número de palavras que as respetivas linhas têm, de modo a obter os tamanhos de letra mais proeminentes por análise dos picos da curva de frequências.

A curva é obtida a partir de um smoothing da lista de frequências e os picos são calculados baseado em proeminência.

Devolve pelo menos um tamanho de letra : `normal_text_size`.

Argumentos:

- `ocr_results` : OCR Tree a analisar
- `method` : método de smoothing. Opções : WhittakerSmoother (por defeito), `savgol_filter`
- `conf` : confiança de texto mínima. Restringe as palavras utilizadas para o cálculo do tamanho das linhas

Algoritmo:

Algorithm 3 Cálculo de tamanhos de texto

```

1: text_sizes = { 'normal_text_size' : 0 }

2: lines ← obtém linhas da OCR Tree

3: line_sizes = []

4: // Cálculo das frequências de tamanhos das linhas

5: for line in lines do
6:   if line não é vazia e não é texto vertical then
7:     lmh ← altura média da linha (arredondado a inteiro)

```

```

8:     linhe_sizes[lmh] ← soma 1 + peso (nº palavras de confiança na linha)
9:   end if
10: end for
11: // smoothing das linhas
12: // WhittakerSmoother : lambda = 1e1; order = 3; data_length= len(line_sizes)
13: // savgol_filter : window_length = round(len(line_sizes*0.1)); polyorder = 2
14: line_sizes_smooth ← smooth de line_sizes usando o método escolhido
15: // cálculo de picos utilizando a função find_peaks do módulo spicy com proeminência a 10% da
   frequência máxima
16: peaks_smooth ← cálculo dos picos
17: text_sizes['normal_text_size'] ← máximo das frequências, i.e. altura mais comum
18: // se houver mais picos, aqueles abaixo do maior serão tamanhos de letra pequena e da mesma
   forma para picos acima do maior

```

get_columns

Descrição: Analisa as frequências das margens das bounding boxes dos blocos de nível 2, pesados pelo número de palavras que os respetivos blocos têm, de modo a obter os pontos esquerdos e direito mais proeminentes por análise dos picos das curvas de frequências.

A curva é obtida a partir de um smoothing da lista de frequências e os picos são calculados baseado em proeminência.

Devolve uma lista do tipo Box com o espaço das colunas encontradas.

Este método é bastante dependente da qualidade dos blocos reconhecidos, sendo que em geral é recomendado usar o método com o mesmo objetivo mas abordagem de análise de imagem, discutido na secção de processamento de imagem.

Argumentos:

- ocr_results : OCR Tree a analisar
- method : método de smoothing. Opções : WhittakerSmoother (por defeito), savgol_filter
- conf : confiança de texto mínima. Restringe as palavras utilizadas para o peso das frequências das margens

Algoritmo: Algoritmo semelhante ao método get_text_sizes mas com análise das margens esquerda e direita das bounding boxes de nodos de nível 2. São calculados os picos de margens esquerdas e direitas separadamente que são depois pareados de forma a formar o espaço das diferentes colunas.

Limpeza de OCR Tree

Como já descrito anteriormente, com a norma dos resultados da aplicação de OCR em documentos antigos, surge a oportunidade de criar um conjunto de métodos que ajudem numa "limpeza" geral dos resultados, de forma a, por exemplo: remover elementos de ruído; unir blocos com características semelhantes; separar blocos demasiado afastados; ajustar dimensões das bounding boxes, etc..

Descrevem-se então alguns dos métodos propostos para resolver alguns destes problemas.

block_bound_box_fix

Descrição: Ajuste de bounding boxes para eliminar interseções.

Argumentos:

- ocr_results : OCR Tree a limpar
- text_confidence : confiança de texto mínima. Utilizado para verificar se blocos são vazios
- find_delimiters : flag que indica se verificação por delimitadores é realizada apenas por verificação do atributo "type" ou utilizando o método "is_delimiter" de OCR_Tree
- find_images : flag que indica se verificação por imagens é realizada apenas por verificação do atributo "type" ou utilizando o método "is_image" de OCR_Tree

Algoritmo:

text_bound_box_fix

Descrição: Ajuste de bounding boxes para apenas englobar o texto confiáveis dentro delas.

Argumentos:

- ocr_results : OCR Tree a ajustar
- text_confidence : confiança de texto mínima. Utilizado para filtrar blocos de texto confiáveis

Algoritmo:

Algorithm 4 Cálculo de tamanhos de texto

- 1: blocks ← obtém nodos de nível 2
- 2: text_blocks ← filtra blocks para apenas ter blocos com texto
- 3: // Percorre blocos com texto para ajustar as suas BBs
- 4: **for** b in text_blocks **do**
- 5: words ← obtém lista de palavras confiáveis, não vazias

```

6:   block_min_left ← valor da palavra mais à esquerda
7:   block_max_right ← valor da palavra mais à direita
8:   block_min_top ← valor da palavra mais acima
9:   block_max_bottom ← valor da palavra mais abaixo
10:  if valores calculados ajustam caixa para ser menor then
11:    b.box ← atualiza tamanho da caixa e dos seus filhos
12:  end if
13: end for

```

remove_solo_words

Descrição: Remove blocos com uma única palavra que estão dentro de outros blocos. Estes são blocos que por esta característica podem ser identificados como ruído ou, em caso negativo, iriam causar conflito no output final por não estarem propriamente integrados no bloco devido.

Argumentos:

- ocr_results : OCR Tree a limpar
- conf : confiança de texto utilizada para análise a nível das palavras

unite_blocks

Descrição: Une verticalmente blocos com o mesmo valor de atributo "type". Apenas aplica união entre blocos adjacentes e horizontalmente alinhados. Nota : blocos de texto vertical, apenas podem unir com blocos de texto vertical.

Argumentos:

- ocr_results : OCR Tree a limpar
- conf : confiança de texto utilizada para verificação de blocos vazios

Algoritmo:

Algorithm 5 União de blocos

```

1: blocks ← obtém nodos de nível 2
2: target_block ← escolhe bloco não visitado
3: // Percorre blocos com texto para ajustar as suas BBs
4: while não tiver visitado todos os blocos do
5:   united = False

```

```

6:    bellow_blocks ← lista de blocos adjacentes, diretamente abaixo
7:    bellow_blocks ← filtra pelos blocos do mesmo tipo que target_block e horizontalmente alinhados
8:    if bellow_blocks then
9:        if target_block é texto vertical then
10:            bellow_blocks ← filtra para apenas manter texto vertical
11:        end if
12:        if len(bellow_blocks) == 1 then
13:            target_block ← une com bloco
14:            ocr_results ← remove bloco unido
15:            // atualiza lista de não visitados
16:        end if
17:    end if
18:    // Se não tiver unido, escolhe novo bloco, senão repete verificação
19:    if not united then
20:        target_block ← escolhe próximo bloco não visitado
21:    end if
22: end while

```

split_whitespaces

Descrição: Separa blocos com espaçamento entre palavras suficientemente grande. Apenas realiza divisão perpendicular ao eixo x. Tem em conta uma análise do texto para calcular o espaçamento médio de palavras e um valor de ratio de espaço vazio para realizar divisão, analisa a presença de espaços brancos em blocos com texto e divide-os quando as condições se verificam. No caso de blocos com múltiplas linhas, tem de verificar se existe um espaço vazio comum válido.

Argumentos:

- ocr_results : OCR Tree a limpar
- conf : confiança de texto utilizada para verificação de blocos vazios e análise de texto
- dif_ratio : ratio de espaço entre palavras para realizar divisão

Algoritmo:

Algorithm 6 Divisão por espaços vazios

```

1: text_analysis ← analise do texto
2: avg_word_dist = text_analysis['average_word_distance']

```

```

3: blocks ← obtém blocos com texto
4: // Percorre blocos com texto para ajustar as suas BBs
5: for block in blocks do
6:     lines ← obtém linhas do bloco
7:     line_seq_positions = []
8:     valid_split = True
9:     // Para cada linha procura espaços vazios para divisão e guarda as coordenadas destes
10:    for line in lines do
11:        line_words ← obtém palavras da linha
12:        line_seq_position = [None,None]
13:        line_word_dists ← guarda as distâncias entre palavras na linha
14:        line_word_pairs ← guarda pares de palavras
15:        if line_word_dists then
16:            average ← média entre a média do tamanho das palavras e o avg_word_dist
17:            line_seq_position ← procura primeiro espaço que valide a regra  $dist \geq diff\_ratio * average$ 
18:            if not line_seq_positio then
19:                // todas as linhas têm de ter um espaço válido
20:                valid_split = False
21:            else
22:                line_seq_positions.append(line_seq_position)
23:            end if
24:        end if
25:    end for
26:    if valid_split and line_seq_positions then
27:        // verifica se todos os intervalos guardados intersetam
28:        // em caso positivo, verifica o máximo tamanho da divisão a fazer
29:        widest_interval ← espaço entre palavras mais longo
30:        interception ← verifica se todas as linhas têm um espaço que está dentro de widest_interval
31:        if interception then
32:            left ← ponto mais à esquerda entre todos os espaços
33:            right ← ponto mais à direita entre todos os espaços
34:            division_line ← Box vertical representante da linha de divisão
35:            // realizar divisão
36:            blocks = split_block(block,delimiter,orientation='vertical',keep_all=True,conf=conf)
37:            ocr_results ← atualiza OCR Tree, adicionando novo bloco resultante da divisão
38:        end if
39:    end if
40: end for

```

Categorização de blocos

De forma a poder segmentar com maior precisão documentos, informação adicional sobre os blocos reconhecidos é necessária. Por exemplo, para ser possível identificar um artigo de um jornal, seria expectável agrupar um título e pelo menos uma caixa de texto. Desta forma uma tokenização dos blocos de nível 2 seguindo heurísticas foi desenvolvida.

O método que realiza esta tokenização é **categorize_box**. O método foi desenvolvido com foco na utilização para jornais, sendo que os tipos de elementos identificados é portanto limitada.

A tokenização segue as seguintes regras:

- **text** : bloco com texto, de tamanho dentro do tamanho normal de texto (margem de 10%), ou que não verificou nenhuma das outras regras para blocos de texto
- **title** : bloco com texto, não vertical, com menos de 10 palavras e tamanho maior do que o tamanho normal de texto
- **highlight** : bloco com texto, semelhante a "title", mas com maior número de palavras
- **caption** : bloco com texto, de tamanho menor do que tamanho normal de texto e está diretamente abaixo de uma imagem ou de um bloco do tipo "caption"
- **delimiter** : bloco sem texto e que verifica a regra: $box.width \geq 4 * box.height \vee box.height \geq 4 * box.width$
- **other** : bloco sem texto e que não verificou nenhuma das outras regras para blocos vazios

Blocos de tipo "delimiter" ou "image" são também possíveis de identificar utilizando métodos disponibilizados para processamento de imagem.

No caso de categorização de blocos de texto, são também verificadas certas características:

- **start_text** : texto foi iniciado, i.e. começa com uma letra maiúscula ou com início de diálogo (sinais: ',', '-') seguido de uma letra maiúscula.
- **ends_text** : texto foi terminado, termina com um sinal de pontuação que finaliza uma frase, ou fim de diálogo (".", "?", "!", ",")

Estas características de texto guardam informação relevante utilizada em métodos de cálculos de atração entre blocos.

Divisão de blocos

Uma funcionalidade de extrema utilidade para a manipulação dos produtos de OCR é a capacidade de dividir um bloco em dois, cada um destes novos ficando com parte dos conteúdos do bloco original. Tal operação facilita a remoção de partes ruidosas de um bloco, ou a segmentação de bloco quando este foi incorretamente unido pelo software de OCR. Exemplo: bloco de texto cuja primeira linha tem potencial de ser título, permite facilmente dividir o bloco em o título e restante texto.

Esta é no entanto uma operação de relativa complexidade, visto que é necessário ir descendo na árvore e fazer múltiplas verificações para calcular o melhor destino final (entre os novos blocos) para cada um dos filhos.

A divisão implementada admite dois tipos de corte: horizontal, utilizando um corte perpendicular ao eixo y, tem uma divisão do conteúdo relativamente simples, visto apenas ser necessário verificar quais linhas se mantêm em cada novo bloco, refazendo posteriormente os parágrafos conforme necessário; vertical, utilizando um corte perpendicular ao eixo x, tem a divisão de conteúdo mais complexo, visto ser necessário verificar para cada palavra a que bloco pertence e, posteriormente, refazer as linhas e os parágrafos.

Uma aplicação direta desta funcionalidade será discutida sobre o editor OCR, ferramenta que permite uma visualização mais fácil desta transformação.

split_block

Descrição: Dado um bloco, um delimitador representante do corte a realizar e a orientação do corte pretendida, divide o bloco em 2. Reparte o conteúdo original entre os dois novos blocos de acordo com a área em que melhor se incluem. Dos blocos criados, devolve apenas aqueles que ainda tiverem conteúdo (texto).

Argumentos:

- block : OCR Tree a dividir
- delimiter : Box representante do corte a ser feito
- orientation : orientação do corte a realizar. Opções: "horizontal", "vertical".
- keep_all : flag que indica se todo o conteúdo deve ser restaurado. Em caso negativo, conteúdo que não se inclui totalmente em nenhum dos novos blocos não será incluído. Se positivo, conteúdo em posição de conflito irá para o bloco que possui a maior parte da sua área.

Algoritmo:

Algorithm 7 Divisão de bloco em 2

```

1: new_blocks = [block]
2: if delimitador não interceta com bloco then return new_blocks
3: end if
4: area_1, area_2 ← cria 2 Box para os novos blocos, criadas de acordo com a orientação do corte e a posição do delimitador
5: // listas para parágrafos de cada área
6: blocks_1 = []
7: blocks_2 = []
8: // corte horizontal
9: // obtém todas as linhas e verifica a que área pertencem
10: // reconstrói parágrafos no fim
11: if orientation == "horizontal" then
12:     lines ← obtém nodos de nível 4
13:     area_1_lines, area_2_lines = []
14:     for line in lines do
15:         if line dentro de area_1 then
16:             area_1_lines.append(line)
17:         else if line dentro de area_2 then
18:             area_2_lines.append(line)
19:         else if keep_all then
20:             if line está mais incluída dentro da área 1 then
21:                 area_1_lines.append(line)
22:             else
23:                 area_2_lines.append(line)
24:             end if
25:         end if
26:     end for
27:     if area_1_lines then
28:         blocks_1 ← reconstrói parágrafos de acordo com a metadata (par_num) dos nodos linha
29:     end if
30:     if area_2_lines then
31:         blocks_2 ← reconstrói parágrafos de acordo com a metadata (par_num) dos nodos linha
32:     end if
33: else
34:     // corte vertical
35:     // obtém todas as linhas e para cada uma verifica que palavras pertencem a qual área
36:     block ← da id às palavras para as conseguir remover diretamente
37:     blocks_1 ← copia paragrafos pertence ao bloco
38:     blocks_2 ← copia paragrafos pertence ao bloco
39:     for paragrafo in block do

```

```

40:     par_words ← obtém palavras do parágrafo
41:     for word in par_words do
42:         if word dentro de area_1 then
43:             blocks_2 ← remove palavra da area 2
44:         else if word dentro de area_2 then
45:             blocks_1 ← remove palavra da area 1
46:         else if keep_all then
47:             if word está mais incluída dentro da área 1 then
48:                 blocks_2 ← remove palavra da area 2
49:             else
50:                 blocks_1 ← remove palavra da area 1
51:             end if
52:         end if
53:     end for
54:     // atualiza BB dos parágrafos para representar as modificações
55:     end for
56: end if
57: if blocks_1 then
58:     block.children = blocks_1
59:     block ← atualiza BB para representar modificações do conteúdo
60: else
61:     // se a área 1 não tiver blocos, bloco original é atualizado com a área 2 e só é devolvido um bloco
62:     if blocks_1 vazio then
63:         block.children = blocks_2
64:         block ← atualiza BB para representar modificações do conteúdo
65:     else
66:         // cria novo bloco
67:         new_block ← nova OCR Tree
68:         new_block.children = blocks_2
69:         new_block ← atualiza BB para representar modificações do conteúdo
70:         new_blocks = [block,new_block]
71:     end if
72: end if
return new_blocks

```

find_text_titles

Descrição: Procura analisar blocos da OCR Tree por potenciais blocos de tipo título que podem ser separados de blocos de texto. Quando potenciais títulos são encontrados, divide o bloco original de modo

a separar em bloco(s) texto e bloco título.

Argumentos:

- ocr_results : OCR Tree a analisar
- conf : confiança de texto mínima.

Algoritmo: Para os blocos de tipo 'text', analisa os seus filhos de nível linha, verificando se poderiam ser categorizados como 'title'. Em caso positivo, utiliza a função de divisão de bloco para separar o bloco 'title' do 'text'. A operação de divisão poderá resultar em 2 blocos, caso o 'title' se encontre no início ou fim do bloco; ou 3, no caso de estar inserido no meio do bloco.

Cálculo de ordem de leitura

No caso de documentos de leitura não linear, como é o caso de jornais, a ordem de leitura proposta pelos motores OCR pode muitas vezes ser incorreto.

Foi então desenvolvido um algoritmo geral, baseado em grafos pesados, para calcular a ordem de leitura do corpo de um jornal. Este algoritmo procura, através de um conjunto de regras sobre as características dos blocos dos resultados OCR, como por exemplo: texto incompleto, texto seguido de título; calcular a atração entre blocos de acordo com as suas características e posição relativa (similar a ordenação topológica); e posteriormente ordenar os blocos, procurando agrupar artigos. Um artigo considera-se como um grupo de blocos, em que o primeiro é um título e não pode ter mais títulos dentro do grupo, a não ser que seja diretamente a seguir ao primeiro título (complementares).

Para conseguir este produto final foi então necessário criar uma estrutura de dados do tipo grafo, neste caso pesado; um método para calcular a atração entre nodos do grafo; e o algoritmo que calcula o caminho do grafo.

Estrutura de dados graph

A estrutura de dados representante do grafo é composta pelas classes:

- Graph : representante do grafo geral

Possui as funcionalidades principais:

- verificações de existência de um nodo
- verificação de existência de caminho entre nodos
- limpeza de caminhos transitivos no grafo

- limpeza de caminhos de baixo peso : em nodos com múltiplos pais, se a atração para um pai é menos de metade do que a atração para outro, remove aresta
- Node : representante de um nodo do grafo Possui as funcionalidades principais:
 - conjunto de pais
 - conjunto de filhos
 - atualizar pais e filhos
 - cálculo de conexão de um nodo a outro
 - limpeza de caminhos de baixo peso : em nodos com múltiplos pais, se a atração para um pai é menos de metade do que a atração para outro, remove aresta
- Edge : representante de um aresta do grafo

Cálculo de atração entre blocos

O cálculo da atração entre dois blocos tem em conta as características dos dois blocos, assim como o contexto da sua vizinhança. O resultado final é o somatório de pontuações adquiridas pela verificação de um conjunto de regras, com diferentes níveis de importância.

Sendo o conjunto de verificações relativamente extenso, segue-se um compilado das condições verificadas, por ordem de relevância:

Atração

- bloco 'image' tem muita atração a bloco 'caption' (vice-versa)
- bloco 'title' é muito atraído a bloco não 'title'
- bloco 'text' inacabado é muito atraído por bloco 'text' não começado diretamente por baixo dele
- bloco é bastante atraído para blocos à sua direita
- bloco 'text' inacabado é bastante atraído por bloco 'text' não começado diretamente à direita dele
- bloco 'title' é bastante atraído por bloco 'text' com texto começado
- bloco é atraído por blocos abaixo dele
- bloco é atraído por bloco à direita se bloco diretamente abaixo abrange os dois blocos
- bloco 'title' é atraído por bloco não 'title'
- bloco 'title' é atraído por bloco 'title' apenas se estiver diretamente abaixo dele
- bloco 'text' é atraído por bloco abaixo mais esquerda
- bloco 'text' é atraído por bloco abaixo

- bloco é um pouco atraído pelo bloco por baixo mais à esquerda
- bloco é um pouco atraído pelo bloco à direita se o bloco mais à esquerda abaixo não tiver texto

Repulsão

- bloco não é um pouco atraído pelo bloco abaixo se o bloco mais à esquerda abaixo não tiver texto
- bloco 'text' não acabado não é atraído por bloco não 'text'
- bloco 'text' não acabado não é atraído por bloco 'text' começado

O método responsável por este cálculo é **calculate_block_attraction**.

Argumentos:

- block : OCR Tree cuja atração por target_block será calculada
- target_block : OCR Tree a comparar
- blocks : lista de OCR Tree para servirem de contexto de vizinhança
- direction : direção entre block e target_block, se nenhuma for dada, direção é calculada. Utilizado para cálculo de distância e verificação de condições. Opções : 'above', 'left','right','below'
- child : flag que indica se cálculo é de pai para filho ou vice-versa

Cálculo da ordem de leitura

O cálculo da ordem de leitura é realizado pelo método **sort_topologic_order** que utiliza um algoritmo de ordenação topológica que utiliza os pesos das arestas para resolver conflitos.

Para escolher o primeiro bloco, ou quando não há mais blocos abaixo do bloco atual, utiliza o método next_top_block que procura dentro de uma lista de potências próximos blocos, o mais apropriado - normalmente o com menor distância ao canto superior esquerdo.

Argumentos:

- topologic_graph : Graph com as ligações dos blocos da OCR Tree a ordenar
- sort_weight : flag que indica se ordenação é apenas topológica ou usa os pesos do grafo para resolver situações de desempate

Os resultados desta ordenação é bastante dependente da qualidade do conteúdo da OCR Tree, sendo que uma OCR Tree com texto muito disperso ou ruidoso irá provavelmente gerar uma ordenação errada.

Diferentes jornais podem não ter métodos de leitura tão simples, ou que acomodem estas regras, sendo que esta metodologia não será ubíqua.

Segmentação de resultados

No caso de jornais, como já discutido anteriormente, o elemento base da informação nestes contido são os artigos.

Artigos podem ser descritos como um título seguido por um excerto de elementos de outro tipo, por exemplo texto ou imagem, quebrado pelo final de página ou por um novo título que iniciaria outro artigo. Seguindo esta caracterização foi desenvolvida um método que, utilizando os resultados do cálculo da ordem de leitura i.e., o grafo e a ordem de nodos calculada, procura formar uma lista de artigos.

graph_isolate_articles

Descrição: A partir de um grafo de nodos de blocos e uma ordem de leitura destes, procura percorrer esta lista para gerar artigos utilizando todos os blocos. Um artigo é começado por um bloco título e, se um novo bloco título for iterado na lista e a lista tiver blocos não título, inicia um novo artigo.

Argumentos:

- graph : Graph com as ligações dos blocos da OCR Tree
- order_list : list de ordem de leitura dos blocos da OCR Tree

Métodos para conversão da lista de artigos para texto, markdown e visualização sob uma imagem foram também desenvolvidos.

6.3 Processamento de imagem

Um outro ponto de abordagem natural quando se trabalha com OCR, é o tratamento do input, que na maior parte dos casos se trata de uma imagem. O estado deste input inicial terá a maior influência na qualidade dos resultados ao longo de todo o processo.

Os principais problemas que se procurou abordar neste trabalho em relação ao tratamento de imagens de documento foram: correção automática de rotações do documento em relação ao texto; remoção de sombras de bainha nas bordas do documento; métodos de binarização para documentos antigos e em mau estado; segmentação de documentos, focando em jornais (divisão entre header e body, divisão de colunas); identificação de imagens/ilustrações no documento; identificação de delimitadores/linhas divisórias no documento.

Além disso, trabalho já realizado para a resolução de problemas como: upscaling, denoising e ajustes na iluminação de imagem; foi reaproveitado, embora maioritariamente para o uso na pipeline desenvolvida

(6).

Esta secção irá abordar os métodos desenvolvidos neste sentido.

Correção de ângulo de rotação

Para imagens de alta definição, i.e. normalmente com dpi elevado e, portanto, mais favorável para realização de OCR, notou-se que mesmo pequenas inclinações no texto podem resultar em resultados de OCR extremamente ruidosos e desorganizados.




Figura 12: Variação dos resultados de OCR em diferentes níveis de rotação de texto.

Foi então desenvolvido um algoritmo com o propósito de automaticamente detetar a existência de uma rotação do texto e, calculando o seu ângulo, corrigi-la.

Este algoritmo foi baseado maioritariamente na solução proposta por [Bieniecki et al. \[2007\]](#) (discutida na secção de estado da arte) com adaptações adicionadas para complementar pontos não explicados da solução e para ser mais viável para documentos com algum ruído.

Na sua essência o algoritmo procura, num documento com texto, analisar as posições do primeiro pixel preto (expectável a primeira instância de texto estar do lado esquerdo) à esquerda em diferentes linhas, para tentar desenhar uma linha, na qual a inclinação será calculada. As adaptações realizadas serviram para fazer uma decisão inicial sobre a direção da rotação, e para, assumindo que se trabalha com imagens com ruído, procurar a linha mais confiável para o cálculo da inclinação.

Para ajustes mais minuciosos, também é aplicado o método de ajuste de rotação da biblioteca leptotica. Este método por si só não é capaz de corrigir ângulos mais consideráveis (+- acima de 6 graus).




Figura 13: Exemplo de aplicação do algoritmo. **1^a** imagem representa a imagem do documento original. **2^a** imagem representa a identificação dos pixels à esquerda no documento. **3^a** apresenta os 3 maiores sets de cada tipo: set de pixels com mesmo x (azul); set de pixels counter-clockwise (verde); set de pixels clockwise (vermelho). **4^a** mostra o ângulo de rotação calculado a partir do maior set. **5^a** tem a imagem corrigida.

calculate_rotation_direction

Descrição: Calcula a direção de rotação num documento de texto. Retorna um dos valores: 'counter-clockwise'; 'clockwise'; 'none'. Cria conjuntos de pontos alinhados (que possibilitem traçar uma reta) para cada uma das direções e, de acordo com qual das direções tem o maior conjunto retorna o identificador dessa direção.

Argumentos:

- `image` : imagem do documento a analisar
- `line_quantetization` : valor de quantetização do eixo y da imagem a usar (para a análise dos pixels)

rotate_image

Descrição: Corrige rotação numa imagem de um documento, se houver. Retorna a imagem com a rotação aplicada. Dada uma direção de rotação, calcula os conjuntos de pixels de texto que formam linhas e com essa dada inclinação no documento. Escolhe o maior destes conjuntos para formar uma linha e calcular a sua inclinação. Aplica uma rotação na imagem para corrigir a inclinação detetada. Se possível, aplica o método `pixFindSkewAndDeskew` de leptonica para correções menores.

Argumentos:

- image : imagem do documento a analisar
- line_quantetization : valor de quantetização do eixo y da imagem a usar (para a análise dos pixeis)
- direction : direção da rotação. 'counter-clockwise', 'clockwise' ou 'auto'. Se auto, aplica o método acima para calcular a direção.
- auto_crop : flag para aplicação do método de cropping de possível bainha na imagem. Estas quando presentes afetam consideravelmente o algoritmo pois não costumam estar alinhadas com o texto.

Corte de sombra nas margens

No caso de documentos com múltiplas folhas, como livros ou jornais, é comum a presença de uma sombra nas margens das páginas. Esta pode, como mencionado anteriormente, impactar a solução para correção de rotação de documento, mas também, quando aplicado OCR, esta sombra poderá ser detetada como um elemento (um tipo de delimitador ou figura) que na realidade gera ruído extra. Pode ser então útil a remoção desta secção da imagem.



Figura 14: Exemplo de documento com inclinação de texto e sombra de bainha.

O algoritmo de remoção segue uma lógica semelhante aos métodos de análise de tamanhos de texto ou de deteção de colunas anteriormente explicados. Na imagem binarizada, é analisada a frequência de pixeis pretos na imagem e, se nas suas extremidades esquerda ou direta (10% de cada uma das pontas)

for detetado um pico seguido de uma descida muito acentuada (igual ou menor a 10% da frequência máxima de pontos pretos) é recortado a zona desse pico da imagem.

cut_document_margins

Descrição: Procura cortar sombras de bainha de uma imagem de um documento. Se estas não existirem, recortam margem da imagem para se aproximar do texto, se este for adjacente a uma zona vazia. Retorna uma instância do tipo Box com as dimensões da imagem recortada.

Argumentos:

- image : imagem do documento a analisar
- method : método de smoothing. Opções : WhittakerSmoothen (por defeito), savgol_filter

Binarização de imagem

Como foi discutido no estado da arte sobre o processamento de imagens, não existe um método de binarização que funcione de forma geral para qualquer tipo de documento, visto que muitas vezes estes são adaptativos e diferentes distribuições dentro da imagem vão gerar resultados diferentes.

Assim sendo, o trabalho realizado neste sentido não foi com o objetivo de propor um método generalista, mas sim de decidir métodos úteis no contexto do trabalho.

Com o trabalho realizado, conclui-se que para documentos com pouco ruído, ou onde este se apresente distribuído pela imagem sem grandes focos particulares, um denoising de médias não locais seguido de uma binarização com algoritmo de Otsu, obtém resultados satisfatórios. Esta binarização é similar à realizada pelo Tesseract. No caso de o ruído estar focado num local específico da imagem, verificou-se que binarizações mais extremas no thresholding, como estilo fax, conseguem obter melhor resultado nas zonas mais afetadas.




Figura 15: Exemplo de resultado de OCR com diferentes binarizações em local com pouco ruído.




Figura 16: Exemplo de resultado de OCR com diferentes binarizações em local com muito ruído.

Um método para cada uma destas binarizações foi desenvolvido.

binarize

Descrição: Binarização utilizando tresholding de Otsu. Realiza limpeza de ruído utilizando algoritmo de médias não locais.

Argumentos:

- image : imagem a binarizar
- denoise_strength : valor de intensidade a utilizar para denoising
- invert : flag para inverter cor de binarização

binarize_fax

Descrição: Binarização utilizando algoritmo de emulação de fax. Algoritmo de emulação proposto pelo orientador Prof. José João. Utilizando métodos do image magick pode ser conseguido como : convert <image> -colorspace Gray (+clone -blur 15,15) -compose Divide_Src -composite -level 10%,90%,0.2.

Argumentos:

- image : imagem a binarizar
- g_kernel_size : tamanho do kernel gaussiano utilizado para o cálculo da imagem desfocada
- g_sigma : valor de sigma do kernel gaussiano utilizado para o cálculo da imagem desfocada
- black_point : valor de thresh de ponto preto, utilizado para ajustar os níveis da imagem
- white_point : valor de thresh de ponto branco, utilizado para ajustar os níveis da imagem
- gamma : valor usado para ajuste do gamma após ajustar níveis da imagem
- is_percentage : flag que indica se valores de black e white point são para serem considerados como percentagem
- invert : flag para inverter cor de binarização

Algoritmo:

Calcula-se primeiramente uma versão desfocada da imagem. Esta será usada para se criar uma distinção entre o plano de fundo e o texto da imagem, ao se dividir a imagem original pela desfocada. Utiliza-se 2 kernels gaussianos por defeito, um aplicado a cada eixo, de dimensão 15 e sigma 15.

Em seguida ajusta-se os níveis dos valores pretos e brancos da imagem de forma a estarem contidos dentro dos valores definidos, 10% e 90% da escala disponível respetivamente.

Por fim, ajusta-se o gamma da imagem para a escurecer.

Identificação de delimitadores

Para documentos estruturados como jornais, certos elementos são utilizados de forma geral para realçar a dada estrutura, como é o caso de delimitadores.

Pode então ser útil conseguir identificar estes elementos para facilitar o seu uso, por exemplo, no cálculo de ordem de leitura de um jornal e cálculo de atração entre blocos.

Estes delimitadores são, por norma, linhas verticais ou horizontais, podendo ser filtradas utilizando um algoritmo similar ao desenvolvido pelo OpenCV [[opencv extract lines](#)]. Este algoritmo é utilizado para separar linhas horizontais do resto da imagem. Adaptando para o propósito de identificar as linhas horizontais, é necessário, após separar as linhas do resto da imagem, utilizar o algoritmo de Hough para identificar as posições e dimensões das linhas existentes.

get_document_delimiters

Descrição: Identifica e devolve uma lista de delimitadores em uma imagem. Delimitadores são linhas horizontais ou verticais. Lista devolvida são objetos do tipo Box.

Argumentos:

- image : imagem a analisar
- tmp_dir : diretório usado para armazenar ficheiros temporários
- min_length_h : valor de comprimento mínimo para um delimitador horizontal válido
- min_length_v : valor de comprimento mínimo para um delimitador vertical válido
- max_line_gap_h : valor de descontinuidade mais comprida aceite para um delimitador horizontal válido
- max_line_gap_v : valor de descontinuidade mais comprida aceite para um delimitador vertical válido
- reduce_delimiters : flag para reduzir/limpar lista de delimitadores, procurando remover ruído

Algoritmo:

Algorithm 8 Identificação de delimitadores (apenas horizontais)

```
1: image ← imagem binarizada
2: morph ← aplica dilatação geral, seguido de linhas horizontais, aplica-se filtro de estruturas para filtrar linhas horizontais
   e, por fim, aplica-se nova dilatação para acentuar as linhas
3: edges ← método Canny para deteção de contornos, seguido de acentuação destes por dilatação
4: horizontal_lines = cv2.HoughLinesP(edges,1,np.pi/100,50,None,minLineLength=min_length_h,maxLineGap=max_line_gap_h)
5: lines = horizontal_lines
6: delimiters = []
7: for line in lines do
8:     // verifica se linhas são verticais ou horizontais
9:     // compara razão entre variação de x ou de y (declives da reta) com tan(60) e tan(5) respetivamente
```

```

10:    is_vertical = dy != 0 and abs(dx/dy) < t5
11:    is_horizontal = dx != 0 and abs(dy/dx) < t60
12:    if is_vertical or is_horizontal then
13:        delimiters ← adiciona Box para linha
14:    end if
15: end for
16: delimiters ← remove delimitadores na borda (provavelmente sombras)
17: if reduce_delimiters then
18:    delimiters ← aplica limpezas sobre lista: remove delimitadores com muitas interseções, une delimitadores próximos
e com a mesma direção, remove delimitadores com muitas componentes ligadas (provavelmente texto)
19: end if
20: delimiters ← remove delimitadores demasiado curtos (menos de 5% do tamanho da imagem)

```

Na generalidade dos casos, a quantidade de linhas detetadas será muito superior aos delimitadores esperados, devido ao ruído, texto do documento e morfologias aplicadas. Diferentes valores de parâmetros para o algoritmo de Hough variam estes resultados.

É então recomendado uma aplicação de métodos para reduzir o número de delimitadores encontrados. Os que foram desenvolvidos foram:

- **remover interseções** : se 2 delimitadores com diferente orientação intersetam, remove o menor
- **une delimitadores** : une delimitadores de igual orientação e suficientemente próximos
- **remover linhas com demasiadas componentes ligadas** : linhas com muitas componentes ligadas, são provavelmente texto, ruído ou outro tipo de elemento, sendo portanto removidas

Identificação de imagens no documento

A possibilidade de identificar e isolar elementos de imagem/ilustração em documentos é, por si só, uma ferramenta extremamente útil. Infelizmente nem todos os motores OCR identificam diretamente estes elementos como sendo imagens, por exemplo, no caso do Tesseract imagens são rodeadas com boa precisão porém, no ficheiro resultante de OCR, não é atribuído um identificador para isolar o elemento como uma imagem (de igual modo para os delimitadores).

Assim sendo, explorou-se abordagens para se obter esta informação de forma mais focada. Entre estas explorou-se abordagens apoiadas por Deep Learning, como é o caso de Detectron desenvolvido pela Meta, e o [Layout Parser](#) que surge a partir do Detectron. Uma solução mais simples em termos de dependências/instalação e computação é o uso de um método de segmentação de página disponibilizado pela biblioteca Leptonica ([método de segmentação](#)). Este método identifica, através de múltiplas aplicações

de morfologias, bounding boxes para zonas previstas de texto e imagem. O código original foi apenas levemente modificado para alterar o destino do output.

identify_document_images

Descrição: Método que invoca algoritmo de leptonica para segmentação de página, interpreta o output deste, e retorna uma lista de objetos do tipo Box que representa a posição das imagens identificadas no documento.

Argumentos:

- image : imagem a binarizar
- tmp_dir : diretório para armazenar ficheiros temporários

Segmentação de documento

Como discutido na secção de métodos aplicados sob os resultados de OCR, a segmentação de um documento tem diversas aplicações. No entanto, como também foi mencionado, a segmentação utilizando os resultados de OCR é muito dependente da qualidade destes, sendo preferível procurar realizar esta diretamente através da imagem.

Para este propósito, foram desenvolvidos métodos para identificação de colunas e para segmentação de documento (header,body,footer).

divide_columns

Descrição: Método que, através de análise da distribuição de pixéis pretos numa imagem de um documento, divide este em colunas. Retorna uma lista de objetos do tipo Box. É recomendado remover ilustrações/imagens do documento pois estes são aglomerados que são outliers na análise de frequências.

Argumentos:

- image : imagem a binarizar
- method : método de smoothing. Opções : WhittakerSmoothen (por defeito).

Algoritmo:

Similar ao utilizado para a deteção de colunas através dos blocos de resultado de OCR, porém a análise de frequências é sobre a distribuição de pixéis invés das margens dos blocos.

segment_document

Descrição: Método que, obtendo uma lista de delimitadores detetados no documento, divide procura dividir o documento em header, footer e body.

Argumentos:

- image : imagem a binarizar
- remove_images : flag para aplicar método de remoção de imagens
- tmp_dir : diretoria de ficheiros temporários
- target_segments : lista segmentos de interesse. Opções possíveis: 'header', 'body', 'footer'

Algoritmo:

Utilizando uma lista de delimitadores horizontais, procura ajustar o body, inicialmente considerado como a imagem inteira, em header e footer (se procurados).

O header é assinalado por um delimitador horizontal que segue a seguinte regra:

$$\text{delimiter.bottom} \leq 0.3 * \text{image.shape}[0] \wedge \text{delimiter.width} \geq 0.4 * \text{image.shape}[1]$$

O footer é assinalado por um delimitador horizontal que segue a seguinte regra:

$$\text{delimiter.bottom} \geq 0.7 * \text{image.shape}[0] \wedge \text{delimiter.width} \geq 0.4 * \text{image.shape}[1]$$

6.4 Processamento de texto

Geração de output

A criação de outputs finais de fácil visualização é uma função essencial do trabalho produzido, permitindo uma digestão dos resultados de OCR mais simples.

Fundamentalmente, existem dois métodos principais de geração de output:

- A partir de uma OCR Tree, chamar o método da classe "to_text" para transformar a árvore numa única string de texto. A ordem do texto seguirá a ordem dos filhos de cada nodo. Delimitadores personalizados para cada um dos níveis podem ser distribuídos através do fornecimento de um dicionário.
- A partir da classe Article, invocar o método "to_text" para transformar a árvore interna processada numa string simples do título seguido do corpo do artigo.

Invocar o método "to_md" para gerar uma string markdown que utiliza uma sintaxe mais apropriada para markdown, adicionando também separador entre o título e o corpo. Neste caso, se o artigo tiver elementos de imagem, é possível que estes sejam incluídos no output final.

Capítulo 7

OSDOCR Pipeline - Implementação

Neste capítulo, será explorada a implementação da componente de pipeline.

De forma a criar um caso de uso para as ferramentas criadas e outras exploradas e disponibilizadas, foi criado um comando de aplicação de uma pipeline de aplicação de OCR, que permite, a partir de uma imagem: aplicar tratamentos para melhorar a sua qualidade; aplicar OCR; tratar os resultados; e gerar um output simples, ou específico para jornais.

Através dos argumentos passados à ferramenta, a pipeline consegue comportar-se de forma diferente, por exemplo: aceitar como output inicial uma instância de Hocr ou de OCR Tree em formato JSON; ignorar pré-processamento ou passos específicos deste; etc.

As funcionalidades disponíveis na pipeline são uma culminação do trabalho descrito anteriormente sobre o OSDOCR Toolkit, assim como ferramentas exploradas para resolver questões que este não aborda como, por exemplo, realização de upscaling de uma imagem.

Como discutido no estudo da solução, os blocos que compõem a pipeline são, sempre que possível, opcionais de modo a aumentar a sua versatilidade.

Além disso, dependendo do modo de utilização da pipeline, output extra pode ser requisitado. Utilizando a flag de debug ('-d' ou '--debug') cada um dos blocos da pipeline irá guardar o seu resultado na forma de um ficheiro situado na diretoria de resultados do input respetivo.

7.1 Sumário

O comando de invocação da pipeline é 'osdocr'. Este apresenta as seguintes opções de utilização:

- **target**
 - **alternativo** : t
 - **descrição** : ficheiro de imagem a ser processado pela pipeline.
- **file**

- **alternativo** : f
 - **Descrição** : ficheiro de texto que lista um target por linha.
- **target_ocr_results**
 - **alternativo** : tocr
 - **Descrição** : ficheiro de resultados OCR. Pode ser de tipo hocr ou json. Se fornecido, não será realizado pré processamento de imagem ou OCR.
- **output_folder**
 - **alternativo** : of
 - **Descrição** : caminho para guardar os resultados
- **segmented_ocr**
 - **alternativo** : sgocr
 - **Descrição** : flag para aplicação de OCR no target será realizada em cada um dos segmentos, invés de na imagem inteira. Cada uma das partes é posteriormente unida para criar uma única OCR Tree de resultados.
 - **valor default** : False
- **target_segments**
 - **alternativo** : ts
 - **Descrição** : segmentos a calcular no target. Segmento body é sempre obtido. O body é ainda repartido nas suas colunas.
 - **opções** : 'header', 'body', 'footer'
 - **valor default** : 'header','body'
- **force_ocr**
 - **alternativo** : focr
 - **Descrição** : flag que ignora possíveis ficheiros em cache de resultados OCR, consequentes de iterações anteriores do target. Força aplicação de na imagem.
 - **valor default** : False
- **tesseract_config**
 - **Descrição** : flags para serem passadas ao Tesseract no momento de aplicação de OCR. Estas estão disponíveis na documentação do Tesseract. Cada argumento tem de ter como prefixo '__' para permitir o seu processamento.
 - **valor default** : __l por
- **text_confidence**

- **alternativo** : tc
 - **Descrição** : valor de confiança de texto que pipeline irá usar.
 - **valor default** : 10
- **split_whitespace**
 - **alternativo** : sw
 - **Descrição** : valor utilizado como razão entre um espaço branco num bloco de texto e a média pesada dos espaçamentos entre palavras, para este ser considerado válido como ponto de divisão de um bloco.
 - **valor default** : 3
- **fix_rotation**
 - **alternativo** : fr
 - **Descrição** : opções usadas para a correção de rotação de documento.
 - **opções** : 'auto','clockwise','counter-clockwise'
 - **valor default** : 'auto'
- **upscaling_image**
 - **alternativo** : upi
 - **Descrição** : opções usadas para o upscaling de imagem. Se opção 'autoscale' do modelo 'waifu2x' for escolhido, aplica upscaling da imagem até esta chegar ao dpi alvo (opção target_dpi).
 - **opções** : 'waifu2x' -> 'scale2x', 'scale4x', 'autoscale'
 - **valor default** : 'waifu2x'
- **target_dpi**
 - **alternativo** : tdp
 - **Descrição** : valor do dpi alvo
 - **valor default** : 300
- **target_dimensions**
 - **alternativo** : tdim
 - **Descrição** : valor das dimensões físicas a usar para cálculo do dpi da imagem. Opções estão disponíveis no ficheiro 'dimensions.json' no projeto, podendo ser atualizado.
 - **opções** : 'A5', 'A4', 'A3', 'A2', 'A1', 'A0', '2A0'
 - **valor default** : A3
- **denoise_image**

- **alternativo** : di
 - **Descrição** : opções usadas para o denoising de imagem.
 - **opções** : 'waifu2x' -> '-1' - '3'
 - **valor default** : 'waifu2x'
- **light_correction**
 - **alternativo** : lc
 - **Descrição** : opções usadas para a correção de iluminação de uma imagem.
 - **opções** : 'best_SSIM', 'best_PSNR', 'LOL-Blur', 'SICE', 'SID', 'w_perc'
 - **valor default** : 'best_SSIM'
- **light_correction_split_image**
 - **alternativo** : lcs
 - **Descrição** : flag para aplicação de correção de iluminação da imagem em patches, invés de na totalidade, de modo a melhorar tempo de processamento. Para certos modelos, resulta em contrastes consideráveis entre os patches.
 - **valor default** : True
- **binarize_image**
 - **alternativo** : bi
 - **Descrição** : opções usadas para a binarização de imagem para aplicação de OCR.
 - **opções** : 'fax', 'otsu'
 - **valor default** : 'fax'
- **remove_document_images**
 - **alternativo** : bi
 - **Descrição** : método utilizado para remoção de imagens.
 - **opções** : 'leptonica', 'layoutparser'
 - **valor default** : 'leptonica'
- **target_old_document**
 - **alternativo** : tod
 - **Descrição** : flag para indicar que target é um documento antigo. Utilizado quando método 'layoutparser' é escolhido, de forma a escolher o modelo mais apropriado
 - **valor default** : True
- **ignore_delimiters**
 - **alternativo** : igd

- **Descrição** : flag para ignorar delimitadores. Se ativada, estes não serão tidos em conta como indicadores do layout do documento no cálculo da ordem de leitura.
- **valor default** : False

- **skip_method**

- **Descrição** : métodos/passos da pipeline a ignorar.
- **opções** : 'leptonica', 'layoutparser'
- **valor default** : 'all', 'auto_rotate', 'noise_removal', 'blur_removal', 'light_correction', 'image_preprocess', 'remove_document_margins', 'remove_document_images', 'image_upscaling', 'identify_document_delimiter', 'binarize_image', 'clean_ocr', 'split_whitespace', 'unite_blocks', 'calculate_reading_order', 'extract_articles', 'posprocessing'

- **calibrate**

- **Descrição** : aplicar modo de calibração de pipeline. Usado para encontrar melhor configuração de pipeline para um dado target. Pode ser dado um diretório onde estarão disponíveis os ficheiros necessários para calibração, e onde ficarão os resultados de calibração; e um diretório com configurações de pipeline a testar. Por defeito, o diretório procurado dá-se por 'calibration' no local onde o comando foi corrido, e são usadas configurações de pipeline disponíveis no projeto.

- **calibrate_no_reuse**

- **Descrição** : flag para não utilizar cache existente.
- **valor default** : False

- **pipeline_config**

- **Descrição** : ficheiro do tipo JSON com configuração de pipeline a usar. Pode ser usado como alternativa a aplicar argumentos no terminal de comandos.

- **gui**

- **Descrição** : aplicar modo de interface gráfica. Interface gráfica simples que pode ser utilizada para experimentar algumas das funcionalidades disponíveis. Maioritariamente usada para debugging.

7.2 Pré-processamento de imagem

Como primeiro procedimento da pipeline, no caso de uso de inputs de imagem, tem-se o tratamento desta, para procurar obter, a partir da aplicação OCR, uma melhor transcrição do conteúdo textual, assim como melhor identificação de outros elementos, como figuras.

Para isso, procurou-se abordar os seguintes problemas: imagens rodadas; remoção de margens/-sombras na margem de documentos; imagens de baixa resolução; remoção de figuras de documentos; imagens com ruído; imagens com distribuição de iluminação inconsistente;.

As solução destes problemas envolveram o uso de métodos desenvolvidos no toolkit, assim como soluções já existentes.

A ordem de aplicação destas soluções mostrou ser relevante pois estas podem interferir umas com as outras, por exemplo: aplicação de denoising antes de remover as figuras do documento pode afetar a identificação destas. Assim sendo, a ordem ótima de execução segue a listagem que se segue.




Figura 17: Pipeline - secção pré-processamento

Correção de rotação

A correção de possíveis rotações de imagens de documentos é resolvida utilizando os métodos de correção de rotação descritos na secção de métodos de processamento de imagem.

Remoção de sombras das margens do documento

De igual modo, a remoção de possíveis sombras na margem de um documento aproveita os métodos desenvolvidos e descritos para este efeito na mesma secção.

A aplicação desta funcionalidade deve vir após a correção de possíveis rotações pois, como esta solução envolve a análise da distribuição dos valores de pixels, se estas sombras se apresentarem inclinadas a possibilidade que elas não sejam resolvidas aumenta.

Upscaling de imagem

Para a resolução de problemas resultantes de imagens com baixos valores de dpi, modelos de Deep Learning obtém resultados mais interessantes em relação a algoritmos passados, como interpolação. Dentro destes modelos, o [waifu2x](#) é bastante respeitado no que toca a aumento de resolução de imagem e limpeza de imperfeições.

Embora não especificamente focado para o processamento de imagens de documentos, o seu fácil uso e instalação, assim como a verificação de bons resultados mesmo nesta área relativamente externa ao treino, levaram a que este modelo seja uma boa adição às ferramentas de pré-processamento de imagem disponíveis na pipeline.

Esta funcionalidade, quando escolhida para realizar upscaling automático, é dependente das configurações utilizadas para cálculo de dpi de imagem (dimensões reais proporcionadas).

A aplicação de OCR é recomendada para dpi no valor de 300 ou superior, sendo que para imagens antigas, esta funcionalidade é essencial.

Remoção de ilustrações de documento

De forma a diminuir a presença de elementos não identificados nos resultados OCR, assim como permitir identificá-los corretamente, esta funcionalidade procura remover as ilustrações de um documento, recortando-as para uma pasta temporário, permitindo a sua reposição na imagem final.

Entre as soluções exploradas para esta questão, a que se enquadrava mais na questão de identificação de ilustrações de documentos, e até com atenção a jornais, foi o modelo [Layout Parser](#), mais especificamente, aproveitando o modelo Detectron desenvolvido pela Meta. Este, no entanto, apresenta uma instalação complexa devido a dependências de bibliotecas da própria Meta que demonstram incompatibilidades e que necessitam ser modificadas manualmente.

Deste modo, aproveitou-se uma alternativa com resultados também satisfatórios e de menor custo computacional, com métodos de segmentação de documento propostos pela Leptonica. Estes foram descritos também na secção anterior.

Comparando os dois, a opção de usar Leptonica é satisfatória na generalidade dos casos, até identificando com maior precisão as ilustrações (delimitando menos fundo do documento) em vários casos de estudo. Os métodos de Leptonica tendem no entanto a errar para ilustrações que não apresentem uma borda notável e tenham um fundo similar ao fundo do documento. Nestes casos, o Layout Parser é mais propício a acertar.

É também importante realçar que a pipeline, no processo de recortar as ilustrações, preenche o espaço vazio com uma média das cores de fundo da imagem. Este passo é importante pois caso contrário

a binarização posterior da imagem, dependendo da distribuição das cores desta, pode resultar numa imagem inutilizável.

Denoising de imagem

Para a realização de denoising, foi também aplicado o modelo de **waifu2x**, visto este proporcionar opções para este efeito. Este denoising é realizado em imagens a cor, sendo portanto subtil.

O denoising mais relevante é realizado na binarização realizada antes da aplicação de OCR.

Correção de iluminação

Para a correção de iluminação de documentos, também se conclui que modelos de Deep Learning são a melhor opção. A família de modelos que mostraram resultados mais interessantes foi [HVI-CIDNet](#). Os pesos para estes estão disponibilizados nesse mesmo repositório.

Para imagens de maior resolução, o tempo de processamento destes modelos é considerável, sendo que como solução a pipeline apresenta uma opção para dividir a imagem em patches e correr o modelo em cada um destes, unindo-os no final. Para alguns modelos, esta divisão pode resultar em contrastes notáveis na imagem.

7.3 OCR

Seguindo na pipeline, temos a aplicação de OCR para extração do conteúdo textual de uma imagem. No caso de input do tipo OCR Tree - ou seu convertível -, este passo é ignorado, caso contrário é obrigatório.

Ao longo da implementação e estudo dos resultados desta, foi utilizado **Tesseract** para a realização de OCR, devido a ser uma ferramenta open-source no topo do estado da arte.

O processo de OCR da pipeline pode ser dividido em blocos menores, sendo estes:




Figura 18: Pipeline - secção OCR

Binarização

A binarização de imagem é um processo que permite a realização de redução de ruído através da aplicação de thresholds, assim como a acentuação do texto de documentos. Este passo é também recomendado na documentação do Tesseract..

Este passo pode ser ignorado na pipeline, até pois o Tesseract internamente irá aplicar uma binarização própria.

A pipeline apresenta a opção de realizar binarização utilizando **Otsu** ou estilo **Fax**.

OCR em imagem

A aplicação de OCR é realizada utilizando **Tesseract** podendo, através dos argumentos da pipeline, modificar a configuração deste, por exemplo: linguagem do texto a detetar; dpi da imagem; modo de segmentação.

Os resultados de OCR serão transformados numa OCR Tree.

OCR em imagem segmentada

Em muitos casos, os documentos antigos apresentam variações do seu estado ao longo do documento. Por este motivo, a pipeline permite a habilidade de realizar um reconhecimento de texto aos diferentes segmentos da imagem, invés de numa única passagem.

Para isto, podem ser passados os segmentos esperados na consola: 'header' , 'body' e 'footer'. Utilizando métodos de processamento de imagem do Toolkit, o documento será dividido nestes segmentos, particularmente o body será possivelmente ainda dividido em colunas, que serão separadamente binarizados (se intedido) e analisados com OCR.

Em seguida as diferentes OCR Tree resultantes serão unidas numa única.

Reconstrução de delimitadores e imagens nos resultados

Com a OCR Tree obtida, o último passo desta secção passa pela reconstrução de elementos não textuais do documento na OCR Tree.

Estes são: ilustrações reconhecidas durante o pré-processamento; delimitadores identificados utilizando o Toolkit (se intedido).

Os elementos serão adicionados na OCR Tree, removendo blocos vazios que se situem dentro ou a intersetar com estes novos elementos.

7.4 Pós-processamento de OCR

Esta secção trata maioritariamente de manipulação da estrutura OCR Tree. A manipulação desta tem, naturalmente, consequências no texto reconhecido, e.x.: processos de eliminação de blocos vazios, estes são reconhecidos através do threshold de confiança definido, sendo que na realidade poderão conter texto.

Esta secção é também o segundo ponto de entrada da pipeline, sendo possível aceder diretamente a este através de um input do tipo Json ou HOCR, convertível para OCR Tree.




Figura 19: Pipeline - secção pós-processamento

Ajustar Bounding Boxes

O primeiro bloco de ação tem como objetivo reduzir a dimensão das bounding boxes dos blocos. Isto consegue-se através do valor dado para threshold de confiança de texto. Fazendo uso deste e do método 'text_bound_box_fix', faz-se uma análise dos nodos de texto dentro dos blocos e, quando ignorados os de confiança abaixo da mínima, é possível reduzir a dimensão do bloco.

Esta ação é importante para diminuir possíveis interseções entre os blocos, normalmente causadas por detecções de ruído como texto. A redução destas interseções auxilia outras ações, como união de blocos ou cálculo da ordem de leitura.

Dividir por espaços vazios

A ação seguinte tem o intuito de dividir texto separado por um considerável espaço vazio em mais do que um bloco. Tal tem tendência a ocorrer na área de menção dos autores de artigos ou ilustrações.

Este bloco é conseguido usando o método 'split_whitespaces'. Os parâmetros de confiança de texto e a razão entre o valor normal de espaço vazio e um válido de separação, são as principais influencias no desempenho deste passo.

Limpeza de delimitadores

Tanto no caso de delimitadores detetados através de métodos de análise de imagem, ou por heurísticas de dimensão dos blocos vazios, é expectável a presença de ruído, e.x.: delimitadores que foram detetados

através do texto de título do jornal por este ser muito acentuado.

Deste modo, a limpeza destes é um passo recomendado. Esta consegue-se através de um método criado para este propósito da pipeline: 'delimiters_fix'. Este método analisa os delimitadores e, validadas certas condições, aplica limpezas, ex.: delimitador inserido completamente dentro de texto -> remove delimitador; delimitador a interseção com texto -> ajusta bounding box do delimitador.

Limpeza de blocos

Segue-se o passo de limpeza geral de blocos, tratando casos de interseções, blocos vazios e blocos inseridos em outros. Para isto é usado o método 'block_bound_box_fix'.

Categorização de blocos

O passo de categorização de blocos é essencial para as ações posteriores de união de blocos, procura por títulos e cálculos de atração entre blocos. Não sendo uma ação impactante da OCR Tree, apenas atualizando o atributo 'type', este é um bloco obrigatório na pipeline.

União de blocos

A união de blocos auxilia o passo de cálculo da ordem de leitura, e realiza uma simplificação da OCR Tree. O objetivo é a redução da quantidade de blocos existente ao unir aqueles que são do mesmo tipo e aceitam determinadas condições geométricas.

A união de blocos pode realçar posição relativa entre estes e outros que anteriormente não eram expressas, potencializando o cálculo da atração entre blocos.

Procura por títulos

O bloco de procura por títulos pretende corrigir casos em que a segmentação em blocos do motor OCR uniu texto com potencial de título (de artigo sendo esse o foco do projeto) do texto seguinte.

Tal permitirá em passos seguintes, de isolamento dos artigos, a identificação de mais artigos do que na ausência deste passo, dado que os artigos são distinguidos pela deteção de títulos.

No caso de serem detetados novos títulos, o método 'find_text_titles' irá dividir o bloco de texto, gerando o novo bloco título e 1 a 2 (dependendo da posição relativa do título) blocos texto.

7.5 Geração de output

A última secção da pipeline passa pela geração do output final em formato textual.

Nesta, a pipeline da opção de escolher: a geração dedicada a jornais, onde a flag 'extract_articles' está ativa e portanto os artigos serão isolados para o output final; ou output simples. Em ambos os casos é ainda possível aplicar o bloco de cálculo da ordem de leitura e escolher o formato do output textual.

Os formatos para output final disponíveis são: texto simples; markdown.




Figura 20: Pipeline - secção output

Cálculo da ordem de leitura

O bloco de cálculo da ordem de leitura pretende, através do cálculo de atração entre blocos - que dependem das características dos blocos assim como posições relativas - do corpo do documento, e de uma ordenação topológica pesada, gerar uma ordenação mais próxima da intendida do que originalmente decidida pelo motor OCR. Como explicitado anteriormente, os algoritmos desenhados têm um foco na ordenação de jornais.

Isolamento de artigos

O passo de isolamento de artigos procura, dentro da lista de blocos ordenados, segmentá-los em diferentes artigos. Os artigos são caracterizados por serem iniciados por um título e possuírem texto além

deste.

O resultado final será uma lista de listas OCR Tree do nível bloco, i.e. uma lista de artigos.

7.6 Validação de resultados

O comando que aciona a pipeline apresenta ainda uma aplicação alternativa. Esta outra aplicação é dedicada à verificação/validação dos resultados da utilização da pipeline e, consequentemente, calibrar a mesma.

Esta utilização, ao contrário da pipeline, não é de independente do utilizador, necessitando que este provisione recursos extra além da imagem de input inicial. Estes recursos extra são respetivos a resultados esperados do output: ground truth total; ground truth parcial; ficheiro de resultados esperadas. Destes, pelo menos uma das ground truth deve ser fornecida. Além disso, pelo menos uma pipeline tem de ser fornecida para serem analisados os seus resultados no input.

O caso de uso esperado é a de, para uma coleção de um dado jornal, em que as diferentes edições têm características semelhantes, o utilizador forneça para uma destas estes recursos para comparação, assim como uma lista comprehensiva de diferentes pipelines com diferentes configurações que serão comparadas e, entre estas, serão escolhidas as opções que melhores resultados obtiveram.

Os métodos utilizados nesta funcionalidade são, na generalidade, dedicados à mesma, não tendo sido implementados com a mesma filosofia de independência do toolkit.

Ground truth total

A ground truth total trata-se de uma transcrição completa do texto do documento.

Ground truth parcial

A ground truth parcial trata-se de uma transcrição de apenas alguns trechos do documento, que devem estar ordenados corretamente, ex.: uma frase de cada uma dos artigos do jornal.

Ficheiro de resultados esperados

O ficheiro de resultados contém informação além do output textual final. Este pode conter: o número de artigos que o output final deve ter; número de ilustrações que o documento contém; número de colunas do jornal.

Comparação dos resultados e calibração da pipeline

Dada um conjunto de pipelines para serem comparadas, para cada uma seguirá o seguinte processo:

Aplicação da pipeline no input, guardando os seus outputs numa pasta própria.

Apuramento dos resultados da pipeline, nomeadamente:

- nível médio da confiança do texto
- número de palavras
- similaridade de cosseno entre o texto e a ground truth total
- número de linhas iguais entre ground truth parcial e o texto
- número de linhas iguais entre ground truth parcial e o texto na ordem certa
- número de colunas detetadas
- número de ilustrações detetadas
- número de artigos detetados

Atribuição de uma classificação numérica a cada secção da pipeline ao comparar os resultados obtidos com os recursos dos resultados esperados. As secções classificadas são o pré processamento e o pós processamento.

Calibração da pipeline ao comparar os diferentes classificações das pipelines e, escolhendo para cada secção as configurações da pipeline (respetivas à dada secção) que nela teve melhor classificação.

É também possível apenas realizar a classificação de uma pipeline única.

Capítulo 8

OSDOCR Editor - Implementação

Neste capítulo será analisada a implementação do último módulo da solução OSDOCR, um editor de OCR Tree gráfico. Este vem com o propósito de servir como uma outra aplicação do Toolkit criado, maioritariamente no que toca às ferramentas que rondam a estrutura OCR Tree, assim como um complemento para a OSDOCR Pipeline que, em casos mais complexos, ou para outros tipos de documentos que não foram o foco da solução, requeira uma manipulação dos resultados mais manual. O editor gráfico facilita esta manipulação.

Embora todos os níveis da OCR Tree possam ser transformados com o editor, o objetivo principal é a de trabalhar com os de nível 2, sendo este nível o que será desenhado na tela de edição.

Esta interface gráfica foi criada utilizando para a parte visual e controlo das Views as bibliotecas **PySimpleGui** e **Matplotlib**; e para módulo de dados e controlador destes o Toolkit, com a opção de utilizar a Pipeline para a realização de OCR localmente no input.

8.1 Sumário

Segue-se uma listagem das funcionalidades que serão realçadas:

- Inputs
- Manipulação manual de OCR Tree
- Aplicação local de OCR
- Ferramentas disponíveis
 - Divisão de blocos
 - Junção de blocos
 - Categorização de blocos
 - Ordenação de blocos
 - Segmentação de blocos em artigos
 - Divisão de imagem
- Outputs

- Operações adicionais

8.2 Funcionalidades

8.2.1 Inputs

Naturalmente, a primeira funcionalidade a ser discutida são os tipos de ficheiros de entrada necessários e admitidos pelo editor.

Sendo este um editor de OCR Tree, poderia se esperar que o único input necessário seria um ficheiro compatível com OCR Tree, no entanto, a utilidade da ferramenta seria consideravelmente limitada se o utilizador não tivesse a imagem par da OCR Tree para servir como fundo. Tomou-se então a decisão que são necessários 2 inputs para iniciar a tela de edição do GUI, uma imagem de input e um ficheiro convertível para OCR Tree - seja este um Json ou HOCR.

Realça-se que a imagem e a OCR Tree podem não corresponder, sendo responsabilidade do utilizador escolher os inputs corretamente pareados.

A tela resultará na OCR Tree sobreposta na imagem de input. Se estes estiverem propriamente pareados, os blocos desenhados estarão corretamente alinhados com o texto respetivo na imagem.

Numa nota extra sobre os inputs: o editor possui uma opção nas configurações que permite que ao ser escolhida uma imagem de input, seja procurada automaticamente por outputs desta resultantes do uso da pipeline, acelerando o processo de seleção da OCR Tree.

8.2.2 Manipulação manual de OCR Tree

Segue-se o propósito principal da criação do editor gráfico, a facilitação da manipulação manual de OCR Tree.

Utilizando o OSDOCR Editor é possível:

Selecionar blocos clicando nestes usando o rato. Múltiplos blocos podem ser selecionados e consequentemente manipulados em simultâneo. Para desselecionar um bloco, basta clicar neste novamente.

Mover blocos selecionando um ou múltiplos blocos e, com o botão do rato pressionado, mover o cursor para o local desejado.

Redimensionar blocos selecionando um ou múltiplos blocos e, clicando no vértice para pivô de redimensionamento, mover conforme desejado.

Atualizar texto do bloco manualmente, ao selecionar um bloco e, na aba da direita com a in-

formação do bloco, atualizar o texto de acordo e clicar em salvar. No caso de múltiplos blocos serem selecionados, apenas o último selecionado é modificável.

Realça-se que a edição manual do texto leva a perda de alguma informação, nomeadamente as dimensões dos níveis mais profundos dentro do bloco, visto que requerer ao utilizador que delimite as coordenadas e nível de confiança de texto das linhas, palavras ou parágrafos editados iria contra o propósito da edição de OCR Tree facilitada. Estes níveis terão as suas dimensões repartidas de forma uniforme de forma a encaixarem dentro do bloco pai e a confiança de texto será considerada como total (100).

Adicionar um novo bloco clicando no botão do meio do rato no local desejado, ou utilizando o botão com o mesmo efeito.

Remover um bloco selecionando o bloco a remover e clicando no botão para o efeito. No caso de múltiplos blocos selecionados, apenas o último será removido.

8.2.3 Aplicação local de OCR

Em instâncias em que apenas porções da OCR Tree apresentem resultados não satisfatórios, ou se pretenda criar novos blocos de texto, a habilidade de aplicar OCR no local afetado pode ser mais eficiente do que transcrever o texto manualmente por completo.

Isto consegue-se aplicando as primeiras duas secções da pipeline : pré-processamento e OCR. Nas configurações do editor é possível costumizar o pré-processamento realizado (se qualquer) e a binarização aplicada para OCR e as opções para o motor OCR.

A utilização da implementação da pipeline implica que é necessário transformar os outputs desta, transformando a OCR Tree resultante numa de nível 2 e, atualizar as suas coordenadas para fazerem sentido à posição do bloco no input do editor.

Para utilizar esta funcionalidade própria do editor, basta selecionar o bloco alvo e clicar no botão de OCR na aba lateral direita.

8.2.4 Ferramentas disponíveis

Nesta secção serão descritas as funcionalidades conseguidas através do uso do OSDOCR Toolkit. Várias destas já estão presentes no OSDOCR pipeline porém, o editor permite uma utilização mais controlada destas.

Divisão de blocos

A divisão de blocos tem como principal propósito corrigir a segmentação de blocos realizada pelo

motor OCR.

Nesta categoria temos 2 tipos de divisão:

Corte de bloco

Esta funcionalidade não está diretamente disponível na pipeline - embora o toolkit a ofereça e outras funcionalidades na pipeline façam uso deste método - devido a necessitar de um input humano.

Tendo selecionado um bloco para realizar um corte e, em seguida, clicado na funcionalidade de corte, o editor irá entrar no estado especial de recorte. Este é caracterizado por uma linha de corte aparecer sob o bloco selecionado, servindo como auxílio para a divisão do bloco em 2.

Clicando no botão esquerdo do rato neste estado realizará o corte de acordo com a linha visível. O texto será também dividido entre os dois blocos de acordo com a linha de corte escolhida. Naturalmente, a divisão do texto segue na realidade as coordenadas da linha de corte e da OCR Tree respetiva ao bloco, sendo que se a bounding box não estiver propriamente alinhada com o texto respetivo, esta divisão poderá não fazer sentido visualmente.

Divisão por espaços vazios

Esta funcionalidade é semelhante à disponibilizada na pipeline com o mesmo nome.

A distinção principal neste cenário é que pode ser utilizada num ambiente mais controlado, apenas afetando, caso desejado, os blocos selecionados.

Caso nenhum bloco esteja selecionado, todos os blocos serão afetados.

Devido à característica de análise estatística do algoritmo para verificação das razões dos espaços vazios, mesmo no caso de haverem blocos selecionados, será introduzido no método a OCR Tree geral.

Junção de blocos

Utilizando métodos de junção de múltiplas OCR Tree, tal como na pipeline no bloco de união de blocos, esta é uma utilização manual de junção de blocos.

Existem, como discutido no Toolkit, duas formas principais de junção de blocos, horizontal ou vertical.

No caso do Editor, basta selecionar dois ou mais blocos para junção e clicar na ferramenta. O algoritmo de junção irá tentar automaticamente unir os dois textos de modo tendo em conta as suas coordenadas, podendo ficar com linhas intercaladas.

Categorização de blocos

A tokenização dos blocos é especialmente importante para os algoritmos de cálculo de atração entre blocos e consequentemente cálculo de ordem de leitura; e de divisão dos blocos de texto em artigos.

Desta forma, a possibilidade de realizar uma categorização manual, para maior confiança ou correções em relação ao algoritmo automático, é evidentemente benéfico.

Tal pode ser conseguido selecionando um bloco e, na aba de edição do bloco, escolher o tipo deste. Por fim, é necessário clicar para guardar as modificações no bloco.

Por defeito, o editor não ilustra os tipos dos blocos, sendo necessário escolher a opção para os diferentes tipos de blocos serem coloridos.

Ordenação de blocos

O algoritmo que mais beneficia da possibilidade de correções manuais é o de ordenação de blocos. Tal deve-se à notável mutabilidade dos templates de jornais.

Deste modo, o editor permite correções, ou ordenações completas dos blocos, de forma simples. Existem 2 formas de realizar a reordenação de um bloco selecionado: simplesmente escrevendo o lugar do bloco na ordem, embora tal tenha restrições de tempo entre cada número do id premido; na aba de edição do bloco, alterar o id para o desejado e guardar as alterações.

O lugar na ordem dos blocos, serve também como id do bloco, sendo que, para ambos os métodos, no caso de haver conflito entre o id dos blocos, estes serão imediatamente ajustados.

Ao mesmo tempo, também é possível usar o método do Toolkit - também usado na pipeline -, para cálculo automático da ordem de leitura.

Segmentação de blocos em artigos

Na pipeline, a segmentação da OCR Tree em artigos é uma das últimas operações realizadas, sendo o seu output extremamente dependente do sucesso das operações antecedentes. Novamente, a manipulação manual destes aparenta-se útil.

Uma aba específica para edição destes está presente no editor.

Várias operações estão relacionados com a manipulação de artigos:

Segmentação da OCR Tree em artigos utilizando o método semelhante ao discutido para a pipeline.

Adicionar ou remover blocos de um artigo, selecionando o artigo, o que irá atualizar a lista de blocos selecionados com os pertencentes ao artigo. Selecionar blocos não pertencentes ao artigo, no caso de se querer adicionar blocos; ou clicar em blocos dentro dos selecionados, para remover blocos do

artigo. Por fim, atualiza-se o artigo para guardar as alterações.

Adicionar um artigo, ao selecionar bloco(s) e carregar para adicionar um artigo.

Remover um artigo, selecionando o artigo e clicando para o remover.

Alterar ordem dos artigos, ao selecionar um artigo e no botão para subir ou descer o seu lugar na ordem de artigos. Esta ordem tem influência na ordem em que os artigos aparecerão no output.

Divisão de imagem

De forma a facilitar a criação de resultados OCR em locais específicos de uma imagem, foi implementada uma funcionalidade única para o OSDOCR Editor que possibilita o corte de uma imagem.

Esta funciona de forma semelhante ao corte de um bloco, onde será realizado um corte que será visualmente representado por uma linha.

Antes de o corte ser realizado, será questionado qual das partes da imagem se pretende manter.

Realizado o corte, uma nova imagem (recortada da original) será criada, e os nodos da OCR Tree inseridos na área recortada serão adicionados na OCR Tree correspondente a esta imagem. Realça-se que apenas os nodos que apresentem uma bounding box completamente dentro da área serão incluídos, sendo que será recorrente pedaços significativos de texto percam o seu respetivo bloco, no caso de este texto ter continuação numa área fora do recorte.

8.2.5 Outputs

O editor permite ainda a geração de outputs textuais semelhantes aos da pipeline.

É possível a geração de ficheiros do tipo *txt* ou *markdown*, para documentos do tipo jornal - criando artigos caso não existam - ou simples. O tipo de documento pode ser modificado através das configurações do editor.

Este output textual é opcional, ao contrário da pipeline.

A OCR Tree utilizada como input será modificada - caso operações sob ela sejam aplicadas -, sendo portanto um output resultante da utilização do editor.

Utilizando o método de divisão de imagem, o recorte da imagem também será também guardado como uma nova imagem, pareado com o respetivo ficheiro OCR Tree.

8.2.6 Operações adicionais

Serve esta última secção para descrever outras funcionalidades do editor, que se agrupam mais dentro de *quality of life* ao invés de pura manipulação dos dados.

Cache de operações

Como na generalidade dos editores, este não é exceção na habilidade de retroceder e reconstruir operações. Tal permite desfazer ou refazer ações rapidamente, tornando o editor uma ferramenta ainda mais útil para a manipulação destes tipos de dados que podem ser consideravelmente densos.

Esta funcionalidade é possível através do uso de uma cache que vai sendo atualizada após a realização de cada operação.

O tamanho desta cache está por defeito definido para 10, mas pode ser alterado nas configurações do editor.

Filtro de blocos

A habilidade de filtragem é sempre bem vinda em qualquer contexto e, neste caso ela é disponibilizada através do tipo dos blocos.

Sendo que existem certos tipos essenciais para a criação de outputs especiais, como é o caso do "title" para a geração de artigos, a possibilidade para facilmente distinguir quais os blocos deste tipo existentes é essencial.

Altura de blocos

A disponibilização de um referencial de altura para os blocos permite a resolução de conflito entre blocos que se intersetam ou estão dentro de outros.

Nestes casos, se não houver distinção da altura entre estes, não será possível selecionar o pretendido entre os dois.

No entanto, selecionando um dos blocos e, alterando a sua altura, torna-se possível criar distinção entre os dois para mais facilmente selecionar aquele que anteriormente não era diretamente selecionável.

Redimensionamento do input

O editor permite ainda a realização de redimensionamento da imagem de input para facilitar a visualização e edição local da respetiva parte da OCR Tree nesta. A OCR Tree é automaticamente deslocada sempre que um redimensionamento ocorre.

Capítulo 9

Resultados

Nesta secção será realizado um estudo final sobre os resultados conseguidos com as soluções implementadas.

Para tal, optou-se pela criação de um conjunto de casos de estudo de características diversas de modo a observar o impacto das soluções em diferentes circunstâncias. Estes serão discutidos na primeira secção.

Cada um dos módulos principais da solução será individualmente discutido, tendo em conta os seus diferentes propósitos.

9.1 Casos de estudo

9.2 OSDOCR Toolkit

9.3 OSDOCR Pipeline

9.4 OSDOCR Editor

Capítulo 10

Conclusões e trabalho futuro

Neste capítulo será feito um sumário do trabalho e estudo realizado e uma introspeção sobre o trabalho futuro.

10.1 Conclusões

O projeto atual, propõe a concretização de uma ferramenta para melhorar os resultados de softwares de reconhecimento de caracteres em documentos estruturados antigos, em particular, jornais. Para isto, nesta primeira fase, foram definidos os objetivos principais do trabalho, assim como algumas vias de expansão consoante o desenrolar da sua implementação. Além disso, foi realizado um estudo sobre o estado da arte com base em dois aspectos principais: softwares **OCR** e práticas comuns na sua utilização; e exploração sobre trabalhos relacionados a este tema ou técnicas relevantes para a proposta. Com isto, foi possível entender os desafios mais relevantes que se apresentam ao reconhecimento de caracteres, assim como os procedimentos *standard* para os abordar, nomeadamente: pré processamento de imagem, pós processamento de texto, segmentação e métricas de validação; e algumas soluções focadas em tarefas similares ao do atual trabalho. Por último, realizou-se um compilado de algumas tarefas de implementação já realizadas que auxiliaram na percepção dos desafios impostos no tema e ao mesmo tempo uma melhor percepção sobre o funcionamento e capacidade da tecnologia **OCR**.

10.2 Perspetiva de trabalho futuro

Partindo do estado atual do projeto, onde uma base de conhecimento do tema já foi concebida, os futuros passos seguirão maioritariamente na componente prática proposta, i.e. a construção das ferramentas para extração de conteúdo de jornais. Como mencionado nos objetivos, abre-se ainda a possibilidade para um aprofundamento na área de criação de léxicos entre versões de uma mesma linguagem para

possibilitar a modernização do conteúdo extraído pela ferramenta principal.

Bibliografia

Abdullah Almutairi and Meshal Almashan. Instance segmentation of newspaper elements using mask r-cnn. In *2019 18th IEEE International Conference On Machine Learning And Applications (ICMLA)*, pages 1371–1375, 2019. doi: 10.1109/ICMLA.2019.00223.

ALTO. Alto documentação. URL <https://www.loc.gov/standards/alto/techcenter/elementSet/index.html>.

Anukriti Bansal, Santanu Chaudhury, Sumantra Dutta Roy, and J.B. Srivastava. Newspaper article extraction using hierarchical fixed point model. In *2014 11th IAPR International Workshop on Document Analysis Systems*, pages 257–261, 2014. doi: 10.1109/DAS.2014.42.

Raphaël Barman, Maud Ehrmann, Simon Clematide, Sofia Ares Oliveira, and Frédéric Kaplan. Combining visual and textual features for semantic segmentation of historical newspapers. *Journal of Data Mining & Digital Humanities*, Histolnformatics(Histolnformatics), January 2021. ISSN 2416-5999. doi: 10.46298/jdmdh.6107. URL <http://dx.doi.org/10.46298/jdmdh.6107>.

Deepa Berchmans and S S Kumar. Optical character recognition: An overview and an insight. In *2014 International Conference on Control, Instrumentation, Communication and Computational Technologies (ICCI/CCT)*, pages 1361–1365, 2014. doi: 10.1109/ICCI/CCT.2014.6993174.

Wojciech Bieniecki, Szymon Grabowski, and Wojciech Rozenberg. Image preprocessing for improving ocr accuracy. In *2007 International Conference on Perspective Technologies and Methods in MEMS Design*, pages 75–80, 2007. doi: 10.1109/MEMSTECH.2007.4283429.

Thomas Breuel. High performance document layout analysis. 05 2003.

Quang Anh Bui, David Mollard, and Salvatore Tabbone. Selecting automatically pre-processing methods to improve ocr performances. In *2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR)*, volume 01, pages 169–174, 2017. doi: 10.1109/ICDAR.2017.36.

R.M. Samitha Chathuranga and Lochandaka Ranathunga. Procedural approach for content segmentation of old newspaper pages. In *2017 IEEE International Conference on Industrial and Information Systems (ICIIS)*, pages 1–6, 2017. doi: 10.1109/ICIINFS.2017.8300390.

Krishnendu Chaudhury, Ankur Jain, Sriram Thirthala, Vivek Sahasranaman, Shobhit Saxena, and Selvam Mahalingam. Google newspaper search – image processing and analysis pipeline. In *2009 10th International Conference on Document Analysis and Recognition*, pages 621–625, 2009. doi: 10.1109/ICDAR.2009.272.

Mostafa Darwiche, The-Anh Pham, and Mathieu Delalandre. Comparison of jpeg's competitors for document images. In *2015 International Conference on Image Processing Theory, Tools and Applications (IPTA)*, pages 487–493, 2015. doi: 10.1109/IPTA.2015.7367194.

Raghunath Dey, Rakesh Chandra Balabantaray, Surajit Mohanty, Debabrata Singh, Marimuthu Karuppiah, and Debabrata Samanta. Approach for preprocessing in offline optical character recognition (ocr). In *2022 Interdisciplinary Research in Technology and Management (IRTM)*, pages 1–6, 2022. doi: 10.1109/IRTM54583.2022.9791698.

Sébastien Eskenazi, Petra Gomez-Krämer, and Jean-Marc Ogier. A comprehensive survey of mostly textual document segmentation algorithms since 2008. *Pattern Recognition*, 64:1–14, 2017. ISSN 0031-3203. doi: <https://doi.org/10.1016/j.patcog.2016.10.023>. URL <https://www.sciencedirect.com/science/article/pii/S0031320316303399>.

Europeana. Projeto europeana. URL <https://pro.europeana.eu/project/europeana-newspapers>.

Dafang He, Scott Cohen, Brian Price, Daniel Kifer, and C. Lee Giles. Multi-scale multi-task fcn for semantic page segmentation and table detection. In *2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR)*, volume 01, pages 254–261, 2017. doi: 10.1109/ICDAR.2017.50.

HOCR. Hocr documentação. URL <https://kba.github.io/hocr-spec/1.2/>.

KerasOCR. Keras ocr documentação. URL <https://keras-ocr.readthedocs.io/en/latest/examples/index.html>.

Samu Kovanen and Kiyoharu Aizawa. A layered method for determining manga text bubble reading order. In *2015 IEEE International Conference on Image Processing (ICIP)*, pages 4283–4287, 2015. doi: 10.1109/ICIP.2015.7351614.

Ankit Lat and C. V. Jawahar. Enhancing ocr accuracy with super resolution. In *2018 24th International Conference on Pattern Recognition (ICPR)*, pages 3162–3167, 2018. doi: 10.1109/ICPR.2018.8545609.

Laurence Likforman-Sulem, Jérôme Darbon, and Elisa H. Barney Smith. Pre-processing of degraded printed documents by non-local means and total variation. In *2009 10th International Conference on Document Analysis and Recognition*, pages 758–762, 2009. doi: 10.1109/ICDAR.2009.210.

Benjamin Meier, Thilo Stadelmann, Jan Stampfli, Marek Arnold, and Mark Cieliebak. Fully convolutional neural networks for newspaper article segmentation. In *2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR)*, volume 01, pages 414–419, 2017. doi: 10.1109/ICDAR.2017.75.

Rishabh Mittal and Anchal Garg. Text extraction using ocr: A systematic review. In *2020 Second International Conference on Inventive Research in Computing Applications (ICIRCA)*, pages 357–362, 2020. doi: 10.1109/ICIRCA48905.2020.9183326.

Thi Tuyet Hai Nguyen, Adam Jatowt, Mickael Coustaty, and Antoine Doucet. Survey of post-ocr processing approaches. *ACM Comput. Surv.*, 54(6), jul 2021. ISSN 0360-0300. doi: 10.1145/3453476. URL <https://doi.org/10.1145/3453476>.

opencv extract lines. Opencv algoritmo de extração de linhas horizontais e verticais. URL https://docs.opencv.org/4.x/dd/dd7/tutorial_morph_lines_detection.html.

PaddleOCR. Paddleocr documentação. URL <https://github.com/PaddlePaddle/PaddleOCR>.

Lorenzo Quiros and Enrique Vidal. Learning to sort handwritten text lines in reading order through estimated binary order relations. In *2020 25th International Conference on Pattern Recognition (ICPR)*, pages 7661–7668, 2021. doi: 10.1109/ICPR48806.2021.9413256.

Mohamed Ali Souibgui and Yousri Kessentini. De-gan: A conditional generative adversarial network for document enhancement. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(3):1180–1191, 2022. doi: 10.1109/TPAMI.2020.3022406.

Sargur N. Srihari, Ajay Shekhawat, and Stephen W. Lam. *Optical Character Recognition (OCR)*, page 1326–1333. John Wiley and Sons Ltd., GBR, 2003. ISBN 0470864125.

Tesseract. Tesseract documentação. URL <https://tesseract-ocr.github.io>.

Tan Chiang Wei, U. U. Sheikh, and Ab Al-Hadi Ab Rahman. Improved optical character recognition with deep neural network. In *2018 IEEE 14th International Colloquium on Signal Processing & Its Applications (CSPA)*, pages 245–249, 2018. doi: 10.1109/CSPA.2018.8368720.

Parte I

Apêndices

Apêndice A

Trabalho de apoio

Resultados auxiliares.

Apêndice B

Detalhes dos resultados

Detalhes de resultados cuja extensão comprometeria a legibilidade do texto principal.

Apêndice C

Listings

Se for o caso.

Apêndice D

Ferramentas

(Se for o caso)

Utilizadores de \LaTeX devem consultar TUG , o grupo de utilizadores \TeX .

Coloque aqui informação sobre financiamento, projeto FCT, etc. em que o trabalho se enquadra. Deixe em branco caso contrário.